PRUEBA DE ANÁLISIS DE PARADAS

ANÁLISIS INICIAL

De primeras el análisis se hará sobre una parada concreta, la 5939 correspondiente a la linea 401 siendo la quinta parada de la línea. He escogido esta debido a que la considero muy básica para empezar, puesto que esa parada no tiene correspondencia con ninguna otra línea, por lo tanto los datos de ocupación o de subidas/bajadas no se verían afectados en tanto qué otros autobuses puedan pasar por esa parada, lo cual como caso base es mejor.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

np.random.seed(495794)


#ABRIR EL CSV COMO PANDAS DATAFRAME
data_input = pd.read_csv("../data/clean_data_5939.csv", encoding="utf-8", header=0)
dataset = pd.DataFrame(data_input)
```

Borramos las columnas que se duplican, como EventTime, TimeSlot e IdExternal, ya que aparecen en ambas tablas mbot y tbso

```
dataset.drop(columns=["EventDate.1", "EventTime.1", "TimeSlot.1", "IdExternal.1", "Tr
```

Se eliminan aquellas filas cuya ocupación sea < 0, puesto que como se dijo en el documento adjunto con la información de la base de datos, estas instancias no tienen sentido

```
dataset.shape
```

```
(9380, 25)
```

```
dataset = dataset[dataset["Occupation"] >=0]
dataset = dataset[dataset["Occupation"] < 80] #Fijamos 80 como valor arbitrariamente g
```

```
dataset.shape
```

```
(9299, 25)
```

Se han visto afectadas +- unas 80 filas, teniendo en cuenta que días únicos a día de ejecutar la consulta tenemos unos 120 días, es una media estimada de 2 mediciones erroneas cada 3 días de medición

ESTUDIO DE LA OCUPACIÓN

ANÁLISIS DE UN FILTRO BASICO

El objetivo de esta parte es, en base a ciertos filtros, encontrar como resultado variables aleatorias gaussianas. De primeras interpreté o pensé, que un filtro básico sería seleccionar todas las variables de un día, pero el problema de este caso es que las variables conforman una serie temporal a lo largo del día, lo cualhace que las dependencias que existen entre un valor y los antecedentes pasados sea lo suficientemente considerable como para alterar el comportamiento de los datos.

En un caso inicial vamos a tomar el valor de medidas de todoss los lunes de paso de autobús por parada alrededor de las 9 de la mañana, por probar a ver el comportamiento. Para empezar, de cada día únicamente vamos a coger un dato, el más cercano a as 9 de la mañana. Para ello, como la consulta realizada ya está ordenada según franja horaria, bastará con coger el primer dato que aparezca de cada día

```
def extract_first_value(data: pd.DataFrame):
    visited_days = []
    return_data = pd.DataFrame(columns=data.columns)
    for index, row in data.iterrows():
        if row["EventDate"] not in visited_days:
            visited_days.append(row["EventDate"])
            return_data.loc[len(return_data)] = row
    return return_data



data_mondays_9am = dataset[dataset["Weekday"] == "L"]
data_mondays_9am = data_mondays_9am[data_mondays_9am["DayType"] == "LA"]
data_mondays_9am = data_mondays_9am[data_mondays_9am["TimeSlot"] == 9]

data_mondays_9am_first = extract_first_value(data_mondays_9am)
data_mondays_9am_first.drop(columns=["EventDate.1", "EventTime.1", "TimeSlot.1", "IdEx
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot
0	20102025401358152637	68f5e04486761436bc4f1a3c	2025-10-20	09:08:17.5510000	9
1	1108202540187525213688	6899977bc8fbb8531ea0c0be	2025-08-11	09:03:07.4130000	9
2	27102025401357852637	68ff28ea86761436bc978444	2025-10-27	09:02:24.5690000	9
3	061020254013582528872	68e36bbf86761436bcafd6b9	2025-10-06	09:03:01.6310000	9
4	2508202540135895214063	68ac0c98c8fbb8531e1a0ff9	2025-08-25	09:00:36.7210000	9
5	1509202540135815216436	68c7bce286761436bcbdce64	2025-09-15	09:11:45.7310000	9
6	290920254013569528872	68da323086761436bc5fceac	2025-09-29	09:14:31.5430000	9
7	2209202540135575216787	68d0f73786761436bc0e1b5e	2025-09-22	09:01:59.5950000	9
8	070720254013576528400	686b741fe889950da18c1967	2025-07-07	09:10:15.1030000	9
9	171120254013582529383	691ad91486761436bc42bb3e	2025-11-17	09:09:07.1090000	9
10	18082025401358952154 8	68a2d3ebc8fbb8531edc3e1b	2025-08-18	09:07:06.6570000	9
11	0109202540135837217569	68b548b386761436bc303951	2025-09-01	09:13:07.0760000	9
12	131020254013510528400	68eca78a86761436bcffe21e	2025-10-13	09:03:28.5870000	9
13	0311202540135705217279	6908658186761436bcd1da21	2025-11-03	09:05:44.6220000	9
14	040820254013584721491	68905fd3e889950da1a90f1c	2025-08-04	09:20:12.6900000	9
15	1407202540135773219233	6874b0b2e889950da1d865e4	2025-07-14	09:15:33.4470000	9
16	210720254013577329331	687deb53e889950da120e78c	2025-07-21	09:10:38.4460000	9
17	280720254013577328192	688726c6e889950da1656103	2025-07-28	09:11:51.4250000	9

	TripId	IdExternal	EventDate	EventTime	TimeSlot
18	080920254013577522214	68be86fc86761436bc75e111	2025-09-08	09:25:27.5610000	9

A partir de esto vamos a realizar evaluación de la normalidad de los atributos. Para ello vamos primero a mostrar un histograma de cómo se comporta la distribución de probabilidad

```
from scipy.stats import norm

#Esto se usará más adelante si se tratan las series temporales a lo largo de cada día
def project_occupation_in_daytime(data_to_project):
    plt.figure(figsize=(16,6))
    plt.plot(data_to_project["EventTime"], data_to_project["Occupation"])
    plt.xlabel('EventTime')
    plt.ylabel('Occupation')
    plt.title('Evolución de Occupation')
    plt.xticks(rotation=90)
    plt.grid(True, alpha=0.3)
    plt.tight_layout()
    plt.show()

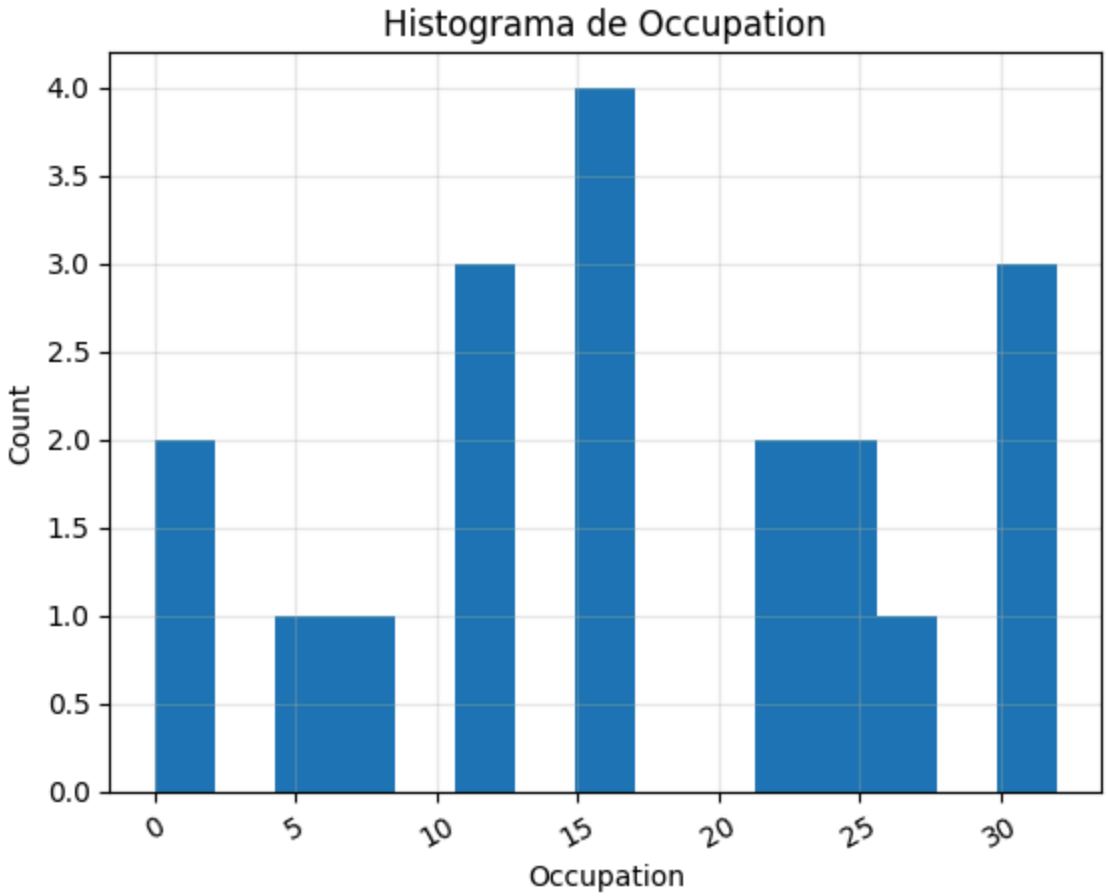
def histogram(data_hist, variable):
    plt.hist(data_hist[variable], bins= 15)
    plt.xlabel(variable)
    plt.ylabel('Count')
    plt.title(f"Histograma de {variable}")
    plt.xticks(rotation=29)
    plt.grid(True, alpha=0.3)
    plt.show()


#Funcion para visualizar un histograma con su normal teórica ajustada(sigma1 y sigma2
def histogram_with_normal(data_to_hist, variable):
    data = np.asarray(data_to_hist[variable])
    mu = np.mean(data)
    sigma = np.std(data, ddof=0)

    # Histograma en densidad
    plt.hist(data,bins = 15, density=True, alpha=0.5, label="Datos")
    x = np.linspace(min(data), max(data), 400)
    y = norm.pdf(x, loc=mu, scale=sigma)
    plt.plot(x, y, 'r-', lw=2, label=f"N({mu:.2f}, {sigma:.2f}²)")

    plt.xlabel(variable)
    plt.ylabel('Densidad')
    plt.title(f"Histograma de {variable} + Normal ajustada")
    plt.xticks(rotation=29)
    plt.grid(True, alpha=0.3)
    plt.legend()
    plt.show()
```

```
histogram(data_mondays_9am_first, "Occupation")
data_mondays_9am_first["Occupation"]
```




```
0     27
1      6
2     25
3      8
4     11
5      0
6     12
7     30
8     17
9     24
10     1
11    31
12    12
13    17
14    22
15    16
16    17
17    23
18    32
Name: Occupation, dtype: object
```

Aquí se ve como la variable occupation tiene una tendencia que a simple vista no se parece mucho a una campana de Gauss, aunque cierto es que con tan pocos datos es dificil a simple vista analizarlo. Para analizar mejor esta tendencia, vamos a someter a estos datos a unos experimentos que miden la simetría y la kurtosis de una variable aleatoria, con el fín de estimar su

"normalidad". Los valores de skewness y kurtosis se miden calculando y estandarizando los momentos centrales de una distribución.

Estos momentos centrales se obtienen a partir de la formulación de los momentos algebráicos, denotados μ'_r donde r especifica el orden

$$\mu'_r = E(x^r) = \sum_k k^r \, p(k) \qquad \text{o} \qquad \int_{-\infty}^{\infty} x^r f(x)\, dx$$

Donde E es la esperanza, x y k son representaciones de la variable aleatoria, tanto en su versión discreta(k), como en su versión contínua(x) y r es el orden de magnitud del momento a calcular.

Estos momentos se calculan a partir del origen, mientras que los momentos centrales, μ_r se calculan sobre el valor de la media, el cual se sabe como el momento algebráico μ'_1. Estos valores μ_r se obtienen a partir de:

$$\mu_r = E\left[(k - E(k)\,)^r\right]$$

De esta fórmula general obtenemos los momentos centrales μ_1 (Media), μ_2 (Varianza), μ_3 (skewness)[sin estandarizar] y μ_4 (kurtosis)[sin estandarizar]. Se puede obtener para una muestra de n observaciones, podemos definir el cálculo de los momentos algebráicos m'_r y de los momentos centrales m_r como:

$$m'_r = \frac{1}{n}\sum_{x=0}^{n} x^r \qquad \text{y} \qquad m_r = \frac{1}{n}\sum_{x=0}^{n} (x - m'_1)^r$$

Por lo tanto, a partir de ahora, como tratamos con muestras, m_r será el equivalente muestral a μ_r.

Ahora, para estandarizar una fórmula general de skewness y kurtosis, se consideran unas fórmulas genéricas a usar en vez de los momentos centrales 3 y 4, que derivan de estos, pero con la siguiente diferencia.

Se considera skewness γ_1 y kurtosis γ_2 como:

$$\gamma_1 = \frac{m_3}{m_2^{3/2}} \qquad \text{y} \qquad \gamma_2 = \frac{m_4}{m_2^2} - 3$$

Donde se denota que los exponentes de los denominadores de ambas fórmulas se usan para eliminar las unidades de los valores γ, puesto que los momentos centrales m_r presentan grado r, y como se comparan estos con la varianza m_2 hay que elevar este exponente a lo necesario para que ambos numerador y denominador estén sujetos a las mismas unidades, y el resultado sea adimensional. También se destaca que de la fórmula de la kurtosis se le resta 3 al valor. Esto es debido a que es un estandar considerar kurtosis como el "sobrante" de kurtosis que tiene la distribución normal. Como la distribución gaussiana presenta kurtosis 3, se resta este valor para considerar este exceso.

Y considerando el error de cada uno de los momentos centrales, como la aproximación mediante el teorema central del límite, se obtienen las fórmulas asintóticas para el SE(Error Estandar) de skewness y Kurtosis como:

$$SE(\gamma_1) = \sqrt{\frac{6}{n}} \qquad \text{y} \qquad SE(\gamma_2) = \sqrt{\frac{24}{n}}$$

Posteriormente se calcula el Z Score tanto para γ_1 como para γ_2 como lo siguiente:

$$Z(\gamma_1) = \frac{\gamma_1}{SE(\gamma_1)} \qquad \text{y} \qquad Z(\gamma_1 2) = \frac{\gamma_2}{SE(\gamma_2)}$$

Como posibles resultados, según los valores de skewness y kurtosis podemos encontrar lo siguiente:

Analizando según skewness (γ_1):

- Valor $0 \rightarrow$ indica simetría **perfecta**
- Valor $> 0 \rightarrow$ la cola derecha es mayor que la izquierda
- Valor $< 0 \rightarrow$ la cola izquierda es mayor que la derecha

Analizando según kurtosis (γ_2)*(Asumiendo kurtosis en exceso)* :

- Valor $0 \rightarrow$ distribución **mesocúrtica**, similar en pico a la normal
- Valor $> 0 \rightarrow$ distribución **leptocúrtica**, con un pico más alto que la normal
- Valor $< 0 \rightarrow$ distribución **platicúrtica**, más achatada que la normal

Para traspasar todo esto a código, se ha hecho uso de las siguientes funciones

```
import math

def central_moment(x, r):
    mean = np.mean(x)
    return sum((xi - mean) ** r for xi in x) / len(x)


def kurtosis(x):
    return (central_moment(x, 4) / central_moment(x, 2) ** 2) -3

def skewness(x):
    return central_moment(x, 3) / central_moment(x, 2)**(3/2)


def general_behaviour(skew_value, kurt_value):
    return_statement = ""
    if skew_value == 0:
        if kurt_value == 0:
            return_statement += "\t-Distribución Normal perfecta"
        else:
            return_statement += "\t-Distribución Normal con simetría perfecta, pero va
            return_statement += "\t-Distribución leptocúrtica" if kurt_value > 0 else
```

```
    else:
        if kurt_value == 0:
            return_statement += "\t-Distribución Normal con kurtosis perfecta, pero va
            return_statement += "\t-Distribución con cola más grande en el lado derech
    if skew_value > 0:
        if kurt_value > 0:
            return_statement += "\t-Cola derecha más grande que izquierda\n\t-Distribu
        else:
            return_statement += "\t-Cola derecha más grande que izquierda\n\t-Distribu
    else:
        if kurt_value > 0:
            return_statement += "\t-Cola izquierda más grande que derecha\n\t-Distribu
        else:
            return_statement += "\t-Cola izquierda más grande que derecha\n\t-Distribu
    return return_statement


def is_normal(variables: list):
    if len(variables) < 50: #CASO Z score 1.96
        z_crit = 1.96
    elif len(variables) < 300: #CASO Z score 3.29
        z_crit = 3.29
    else:
        z_crit = "False"

    skew = skewness(variables)
    kurt = kurtosis(variables)


    n = len(variables)
    se_skew = math.sqrt(6.0 / n)
    se_kurt = math.sqrt(24.0 / n)

    mean = np.mean(variables)
    std_dev = sqrt(central_moment(variables, 2))
    z_skew = skew / se_skew
    z_kurt = kurt / se_kurt

    if z_crit != "False":
        approx_normal = (abs(z_skew) <= z_crit) and (abs(z_kurt) <= z_crit)
        print(f"-Para {n} valores, con valor skewness: {skew} y kurtosis: {kurt}, \n\n
          f"-Con valores de SE, SE_skewness: {se_skew}, SE_kurtosis: {se_kurt}, \n\n"
          f"-Se obtienen los siguientes valores de Z; Z_skew: {z_skew} y Z_kurtosis: {
          f"-Se concluye por lo tanto que la hipótesis de que la distribución es norma
          f"La distribución presenta una media:  {mean} y una desviación estandar σ: {
          f"-El comportamiento general de esta distribución es:\n{general_behaviour(sk

    else:
        approx_normal = (abs(skew) <= 2) and (abs(kurt) + 3 <= 7) #para muestras grand
        print(f"-Para {n} valores, con valor skewness: {skew} y kurtosis: {kurt}, \n\n
              f"-Con valores de SE, SE_skewness: {se_skew}, SE_kurtosis: {se_kurt}, \n
              f"-Se concluye por lo tanto que la hipótesis de que la distribución es n
              f"La distribución presenta una media:  {mean} y una desviación estandar
              f"-El comportamiento general de esta distribución es:\n{general_behaviou
    return None
```

```
is_normal(data_mondays_9am_first["Occupation"])
```

```
-Para 19 valores, con valor skewness: -0.19782242818299264 y kurtosis: -0.93342341267
87733,

-Con valores de SE, SE_skewness: 0.5619514869490163, SE_kurtosis: 1.1239029738980326,

-Se obtienen los siguientes valores de Z; Z_skew: -0.35202759095277614 y Z_kurtosis:
-0.8305195682874482,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: True

La distribución presenta una media:  17.42105263157895 y una desviación estandar σ:
9.444105872663226

-El comportamiento general de esta distribución es:
        -Cola izquierda más grande que derecha
        -Distribución platicúrtica(distribución más achatada de lo normal)
```

En este caso se ve como el experimento ha resultado en una aceptación de la hipótesis de normalidad de los datos. Antes de revisar otros días a la misma hora para analizar el comportamiento, vamos a echarle un vistazo a esos casos más alejados de la media que se obtienen en esta distribución. Para ello, de tener una muestra con un número de población mayor, seguiríamos la regla de capturar todos los datos alejados una distancia de 2σ de la media de la distribución, y a estudiar qué hay(si hay algo) de especial o distinto en esos días. Como de primeras, al trabajar con muestras más pequeñas, vamos a realizar un experimento para identificar aquellos valores detectados como outliers, mediante el test ESD generalizado.

El test ESD Generalizado(*E*xtreme *S*tudentized *D*eviate de las siglas *ESD*) es un test propuesto por Rosner en 1983, el cual, a diferencia de otros test como el de Grubss, o el de Tietjen-Moore que necesitan saber qué numero de outliers se consideran, este test evalúa mediante hipótesis cuál es el número adecuado de outliers para una distribución, para ello recurre a lo siguiente:

El algoritmo define las siguientes hipótesis:

H_0: No hay outliers

H_a: Hay hasta r outliers

Luego, se sigue un proceso iterativo, en el cual se computa la siguiente fórmula para cada iteración i:

$$R_i = \frac{\max_i |x_i - \bar{x}|}{s}$$

Donde $\bar{x}$ denota la media y s es la desviación estándar muestral, que difiere de m_2(desviación estándar de la población) en que en su cálculose multiplica por $\frac{1}{n-1}$ en vez de $\frac{1}{n}$ En cada iteración se encuentra el valor que maximiza esa R_i, y se almacena. En la siguiente iteración $i+1$ se recalcula esa R_{i+1} sin tener en cuenta el valor anterior

Esto se repite hasta que se han computado los r datos de la H_a

Luego, con un nivel definido de significancia α, para cada R_i con $i \in 1, 2, \ldots, i$ se calcula un valor λ_i

$$\lambda_i = \frac{(n-i)\, t_{p,n-i-1}}{\sqrt{\left(n-i-1+t^2_{p,n-i-1}\right)(n-i+1)}}$$

Donde $t_{p,v}$ se corresponde con el cuantil p de la distribución t con v grados de libertad. En estas fórmulas, v se corresponde con $n-i-1$ y p con

$$p = 1 - \frac{\alpha}{2\,(n-i+1)}$$

De todo esto obtenemos que el número de outliers es determinado según el máximo valor i que cumpla que $R_i > \lambda_i$

En código

```
from math import sqrt
from scipy.stats import t as t_student


def calculate_lambda(iter_value, n_elems, significance_level: float = 0.05):
    """

    :param iter_value: the iteration i in which calculate the associate lambda
    :param significance_level:
    :param n_elems:
    :return: The lambda value for that iteration
    """
    calculate_p = 1 - (significance_level / (2*(n_elems - iter_value +1)))

    t_p_v = t_student.ppf(calculate_p, (n_elems - iter_value - 1))

    return ((n_elems - iter_value) * t_p_v)/sqrt((n_elems - iter_value - 1 + t_p_v*t_p



def calc_r_value(element, variables):
    """
    Function to calculate the R value of a data given the sample it belongs
    :param element: The element to calculate the R value of
    :param variables: The complete sample to evaluate mean and sample standard deviati
    :return: The r value for that element
    """


    mean = np.mean(variables)
    s = sqrt(sum((xi - mean) ** 2 for xi in variables) / (len(variables) -1))
    return abs(element - mean)/s
```

```python
def extract_r_parameters(variables: list, r:int):
    """

    :param variables:
    :param r:
    :return:
    """

    #variables = np.array(variables)
    r_parameters = []
    variables_as_dict = {}

    for iteration in range(r):

        for variable in variables:
            variables_as_dict[variable] = calc_r_value(variable, variables)


        item, max_r = 0, 0
        for key,value in variables_as_dict.items():
            if value > max_r:
                max_r = value
                item = key
        r_parameters.append((item, max_r))
        #print(f"DEBUG voy a eliminar {item} con {max_r}")

        variables.remove(item)
        variables_as_dict = {}

    return r_parameters



def estimate_outliers(variables:list, outliers_hipotesis: int, significance_level: flo
    """

    :param variables:
    :param outliers_hipotesis:
    :param significance_level:
    :return:
    """
    r_parameters = extract_r_parameters(variables, outliers_hipotesis)

    #FOR THE FORMATTED EXIT
    print(f"H_0:\tThere are No outliers")
    print(f"H_a:\tThere are up to {outliers_hipotesis} outliers in the data")
    print(f"\nSignificance level : {significance_level}")
    print(f"Critical Region: Reject H_0 if R_i > Critical value")
    print(f"\nSummary Table for EDC Test")
    print(f"-------------------------------------------------------------")
    print(f" Exact             Test                        Critical")
    print(f"Number of          Statistic                   Value, λ ")
```

```
    print(f"Outliers, i         Value, R_i                    5%")
    print(f"-------------------------------------------------------------")

    for iteration in range(outliers_hipotesis):
        iteration_value = calculate_lambda(iteration, len(variables))

        print(f"\t{iteration + 1}\t\t\t{r_parameters[iteration][1]}\t\t\t{iteration_va

    return r_parameters

outliers_mondays = estimate_outliers(data_mondays_9am_first["Occupation"].tolist(), 4)
```

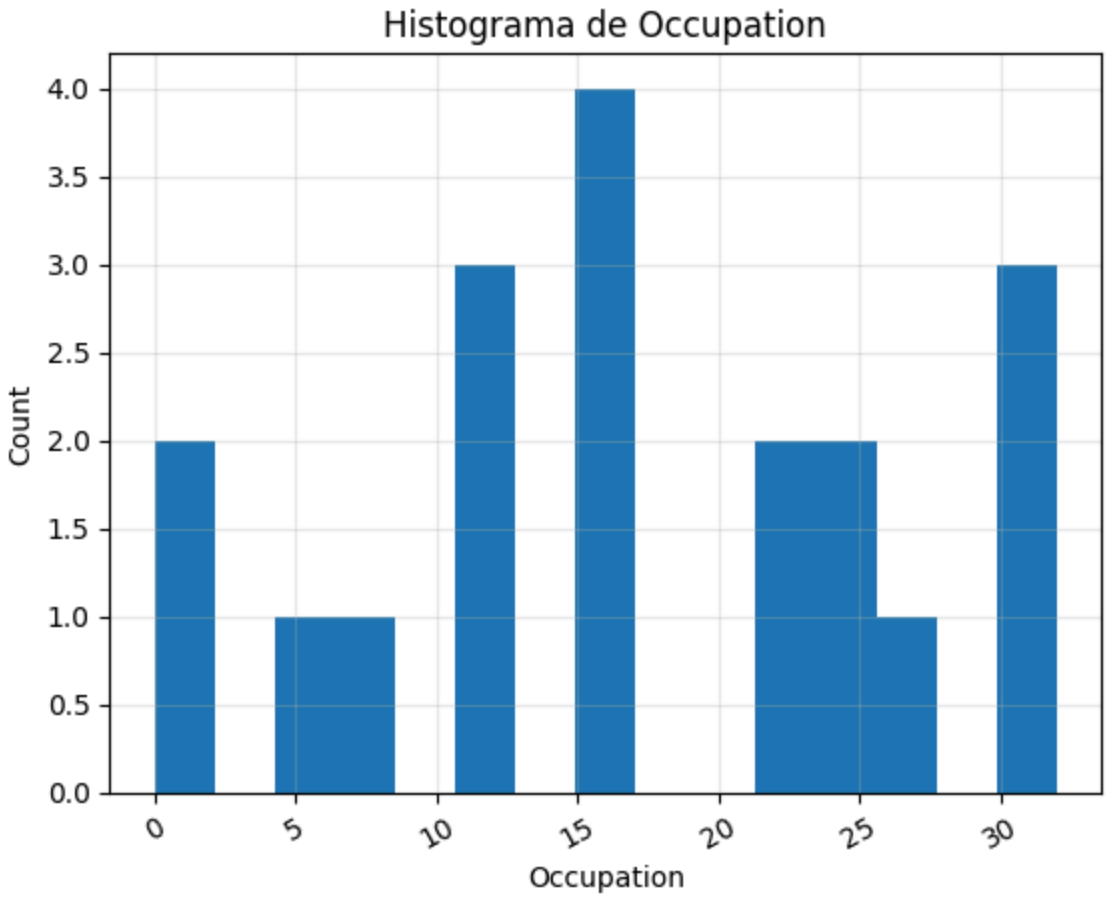
```
H_0:    There are No outliers
H_a:    There are up to 4 outliers in the data

Significance level : 0.05
Critical Region: Reject H_0 if R_i > Critical value

Summary Table for EDC Test
-----------------------------------------------------------
 Exact              Test                        Critical
Number of           Statistic                   Value, λ
Outliers, i         Value, R_i                     5%
-----------------------------------------------------------
        1                       1.7954486874202735                    2.58567634067
19616
        2                       1.9340114064755367                    2.54830777174
33393
        3                       1.6523474516094778                    2.50732085257
88404
        4                       1.6150141076123115                    2.46203286854
26998
```

Tras la ejecución de este experimento para este dataset, se muestra como no se ha aceptado en ninguno de los casos la Hipótesis alternativa de que existian outliers. No obstante, este experimento en este caso puede estar influido por el poco número muestral que se tiene. Se dejará para experimentos con mayores muestras. Aún así, viendo el histograma:

```
histogram(data_mondays_9am_first, "Occupation")
```



Se observaba como la ocupación en la zona máxima (>30) era "notoria" (conteo de 3 para una muestra de 19), por lo que vamos a ver si esos días tenían algo en común distinto al resto.

```
potencial_abnormal_data_mondays = data_mondays_9am_first[data_mondays_9am_first["Occu
potencial_abnormal_data_mondays
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot
7	2209202540135575216787	68d0f73786761436bc0e1b5e	2025-09-22	09:01:59.5950000	9
11	0109202540135837217569	68b548b386761436bc303951	2025-09-01	09:13:07.0760000	9
18	0809202540135775222l4	68be86fc86761436bc75e111	2025-09-08	09:25:27.5610000	9

3 rows × 25 columns

Algo curioso de primeras que se observa en estos valores es, por ejemplo, que 2 de los Lunes, el 1 de Septiembre y el 8 de Septiembre, los coincidentes con días de mayor ocupación a las 9 de la mañana, son días en los que hubo gratuidad,(Ya que FreeDay = 1 en esas instancias). También cabe destacar que la predicción de temperatura a esa hora de la mañana del día que no presenta

gratuidad es 4 y 8~9 grados menor a lo registrado en los otros días. Puesto que este día no tuvo gratuidad, la baja temperatura pudo ser motivo de la alta ocupación.

Vamos a revisar más conjuntos de días a ver si el comportamiento es parecido, por ejemplo de los martes.

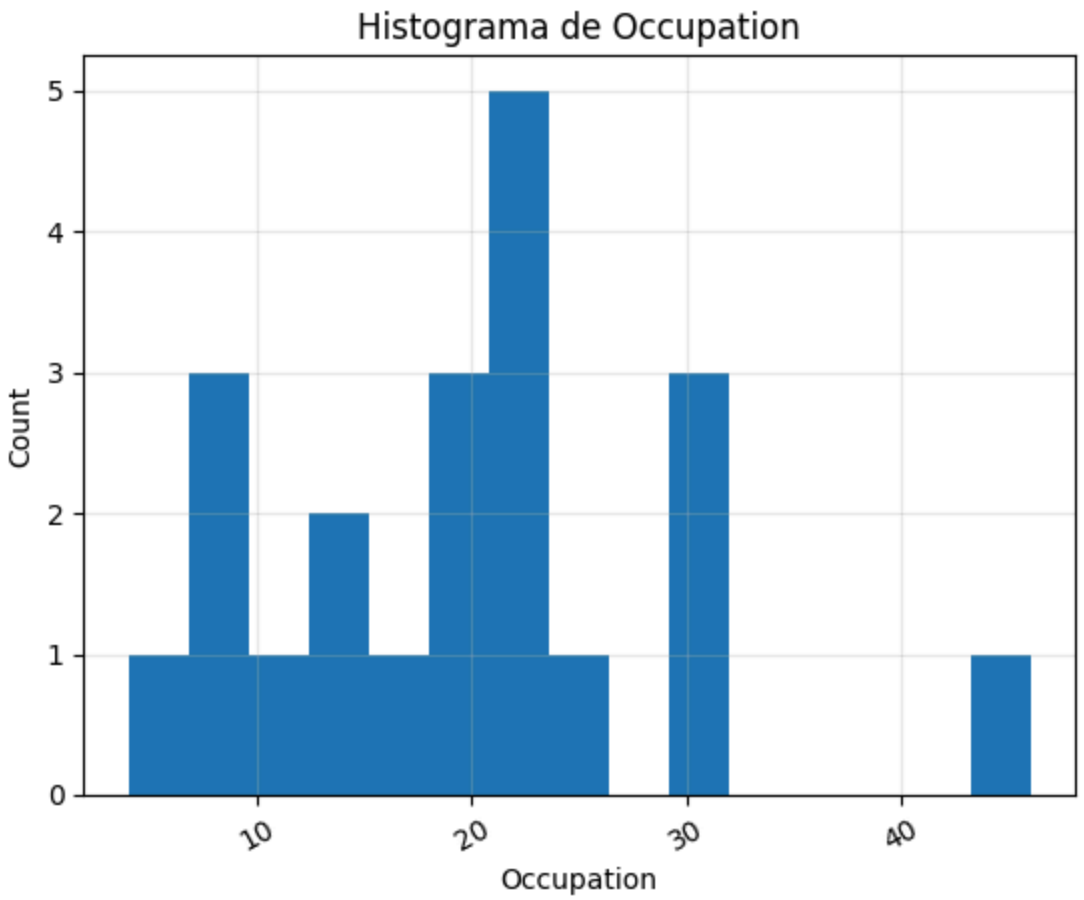
```
data_tuesdays_9am = dataset[dataset["Weekday"] == "M"]

data_tuesdays_9am = data_tuesdays_9am[data_tuesdays_9am["DayType"] == "LA"]

data_tuesdays_9am = data_tuesdays_9am[data_tuesdays_9am["TimeSlot"] == 9]

data_tuesdays_9am_first = extract_first_value(data_tuesdays_9am)
```

```
histogram(data_tuesdays_9am_first, "Occupation")
```




```
is_normal(data_tuesdays_9am_first["Occupation"])
```

```
-Para 21 valores, con valor skewness: 0.7098183706996805 y kurtosis: 0.8143988306923222,

-Con valores de SE, SE_skewness: 0.5345224838248488, SE_kurtosis: 1.0690449676496976,

-Se obtienen los siguientes valores de Z; Z_skew: 1.3279485749981514 y Z_kurtosis: 0.7618003501599969,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: True

La distribución presenta una media:  19.666666666666668 y una desviación estandar σ: 9.443230547572329

-El comportamiento general de esta distribución es:
        -Cola derecha más grande que izquierda
        -Distribución leptocúrtica(picos más altos de lo normal)
```

```
outliers_tuesdays = estimate_outliers(data_tuesdays_9am_first["Occupation"].tolist(),
```

```
H_0:    There are No outliers
H_a:    There are up to 5 outliers in the data

Significance level : 0.05
Critical Region: Reject H_0 if R_i > Critical value

Summary Table for EDC Test
-----------------------------------------------------------
 Exact              Test                        Critical
Number of           Statistic                   Value, λ
Outliers, i         Value, R_i                     5%
-----------------------------------------------------------
        1                       2.72138880773007                       2.6199636398344386 *
        2                       1.848891035289282                      2.5856763406719616
        3                       1.5468221644245757                     2.5483077717433393
        4                       1.7113498977706183                     2.5073208525788404
        5                       1.7875155291152927                     2.4620328685426998
```

```
outliers_tuesdays[0]
```

```
(46, np.float64(2.72138880773007))
```

Tras ver los datos de los martes a las 9 de la mañana podemos extraer las siguientes conclusiones:

- La distribución **También** es normal, aunque presenta cola derecha mayr que izquierda, y picos más altos de lo normal
- Existe 1 outlier, que se corresponde con el valor 46
- La media entre las distribuciones de los lunes y de los martes es similar (17.42 el lunes VS 19.66 el martes) y su desviación estandar es igual en ambos casos (9.44) Vamos a mirar más a fondo el valor anómalo para ver que podemos sacar de él.

```
outlier_tuesday = data_tuesdays_9am_first[data_tuesdays_9am_first["Occupation"] == 46]
outlier_tuesday
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot	Lin
3	230920254013501327585	68d247b886761436bc1b5fa7	2025-09-23	09:06:34.3910000	9	40

1 rows × 25 columns

Se ve como la fecha corresponde con el 23 de septiembre. Concretamente el día consecutivo al lunes 22, día en el cual también hay una presencia anómala de ocupación y no era explicable por gratuidad, por ejemplo. Vamos a revisar el resto de los dias a ver si esa semana fue problemática también para los miércoles

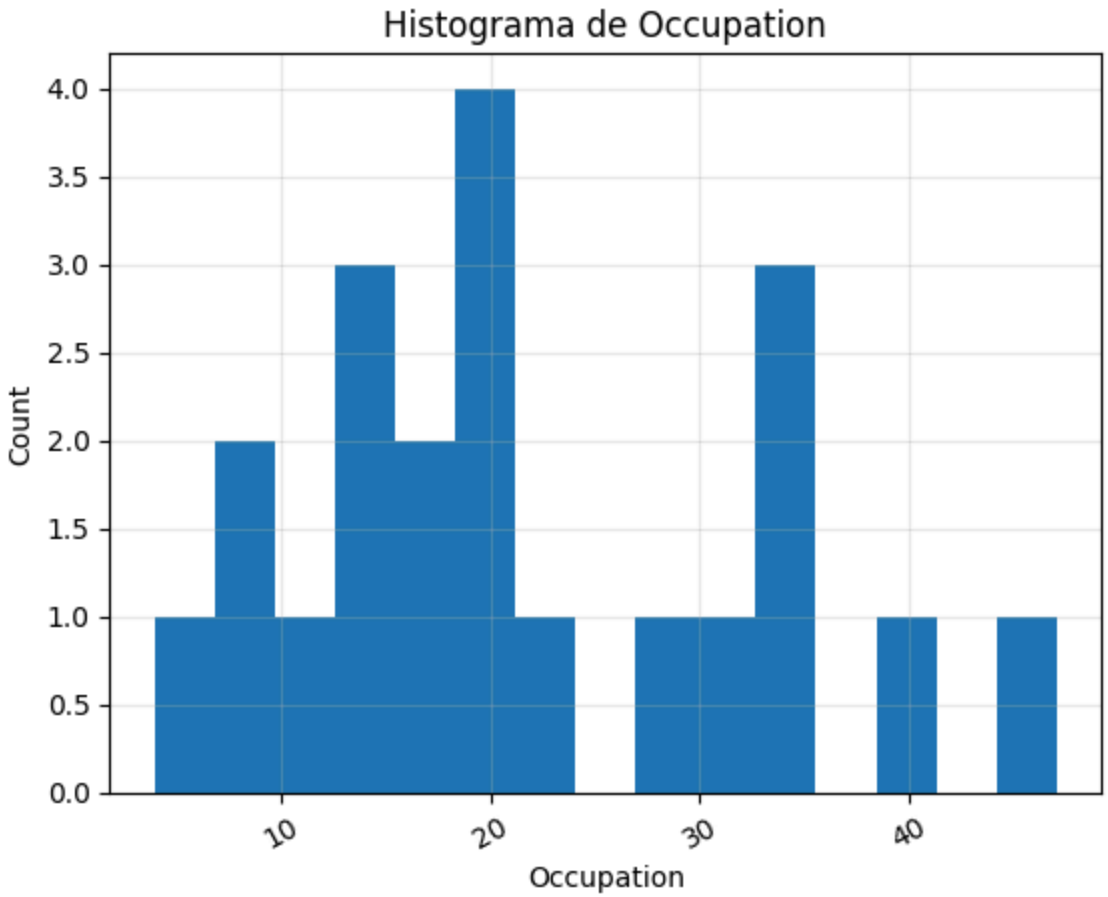
```
data_wednesdays_9am = dataset[dataset["Weekday"] == "X"]

data_wednesdays_9am = data_wednesdays_9am[data_wednesdays_9am["DayType"] == "LA"]


data_wednesdays_9am = data_wednesdays_9am[data_wednesdays_9am["TimeSlot"] == 9]


data_wednesdays_9am_first= extract_first_value(data_wednesdays_9am)
```

```
histogram(data_wednesdays_9am_first, "Occupation")
```




```
is_normal(data_wednesdays_9am_first["Occupation"])
```

```
-Para 21 valores, con valor skewness: 0.4444677326610706 y kurtosis: -0.5659097763323
326,

-Con valores de SE, SE_skewness: 0.5345224838248488, SE_kurtosis: 1.0690449676496976,

-Se obtienen los siguientes valores de Z; Z_skew: 0.8315229875469801 y Z_kurtosis: -
0.5293601237153653,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: True

La distribución presenta una media:  22.238095238095237 y una desviación estandar σ:
11.1650166310616

-El comportamiento general de esta distribución es:
        -Cola derecha más grande que izquierda
        -Distribución platicúrtica(distribución más achatada de lo normal)
```

```
possible_outliers_wednesday = estimate_outliers(data_wednesdays_9am_first["Occupation"
```

```
H_0:    There are No outliers
H_a:    There are up to 5 outliers in the data

Significance level : 0.05
Critical Region: Reject H_0 if R_i > Critical value

Summary Table for EDC Test
-----------------------------------------------------------
 Exact              Test                        Critical
Number of           Statistic                   Value, λ
Outliers, i         Value, R_i                     5%
-----------------------------------------------------------
       1                       2.1643626213917964                     2.61996363983
44386
       2                       1.962154595989138                      2.58567634067
19616
       3                       1.71690755443576                       2.54830777174
33393
       4                       1.6297653558912037                     2.50732085257
88404
       5                       1.710372220988273                      2.46203286854
26998
```

De los miércoles, se puede sacar lo siguiente:

- La distribución también puede asumir la hipótesis de normalidad.
- En las 3 se presenta una cola más alargada en el lado derecho.
- La media presenta un valor algo mayor que la de lunes y martes, aunque tampoco mucho mayor. La desviación estandar también es levemente mayor
- No se reconoce según el ESD ningún outlier

Vamos a ver aún así si alguno de los casos de mayor valor se corresponde con el 24 de septiembre, el cual alargaría la nube que sobrevuela esa semana, debido a que los 2 días anteriores también presentaban un alto valor

```
big_data_wednesdays = data_wednesdays_9am_first[data_wednesdays_9am_first["Occupation"

big_data_wednesdays
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot	Li
10	240920254013582528400	68d39b4d86761436bc289bc0	2025-09-24	09:15:15.0340000	9	4
19	100920254013579722261	68c1311786761436bc8c52d7	2025-09-10	09:55:41.8360000	9	4

2 rows × 25 columns

Otra vez la semana del 22,23 y 24 de septiembre muestra un valor que podría considerarse "fuera de lo común",aunque ahora también aparece otro valor, el día 10 de septiembre, el cual no parece tener una clara motivación por la cual pueda ir más lleno. Una hipótesis podría ser que su timeslot

de la hora de salida es 9, pero el de su hora de llegada a la parada es 10, lo que quizas al ser un bus siguiente tenga unos datos distintos.

Por tener todos los días. Vamos a ver también las distribuciones de los jueves y los viernes a ver que conclusiones generales podemos sacar.

```
data_thursdays = dataset[dataset["Weekday"] == "J"]

data_thursdays = data_thursdays[data_thursdays["DayType"] == "LA"]

data_thursdays_9am = data_thursdays[data_thursdays["TimeSlot"] == 9]

data_thursdays_9am_first = extract_first_value(data_thursdays_9am)

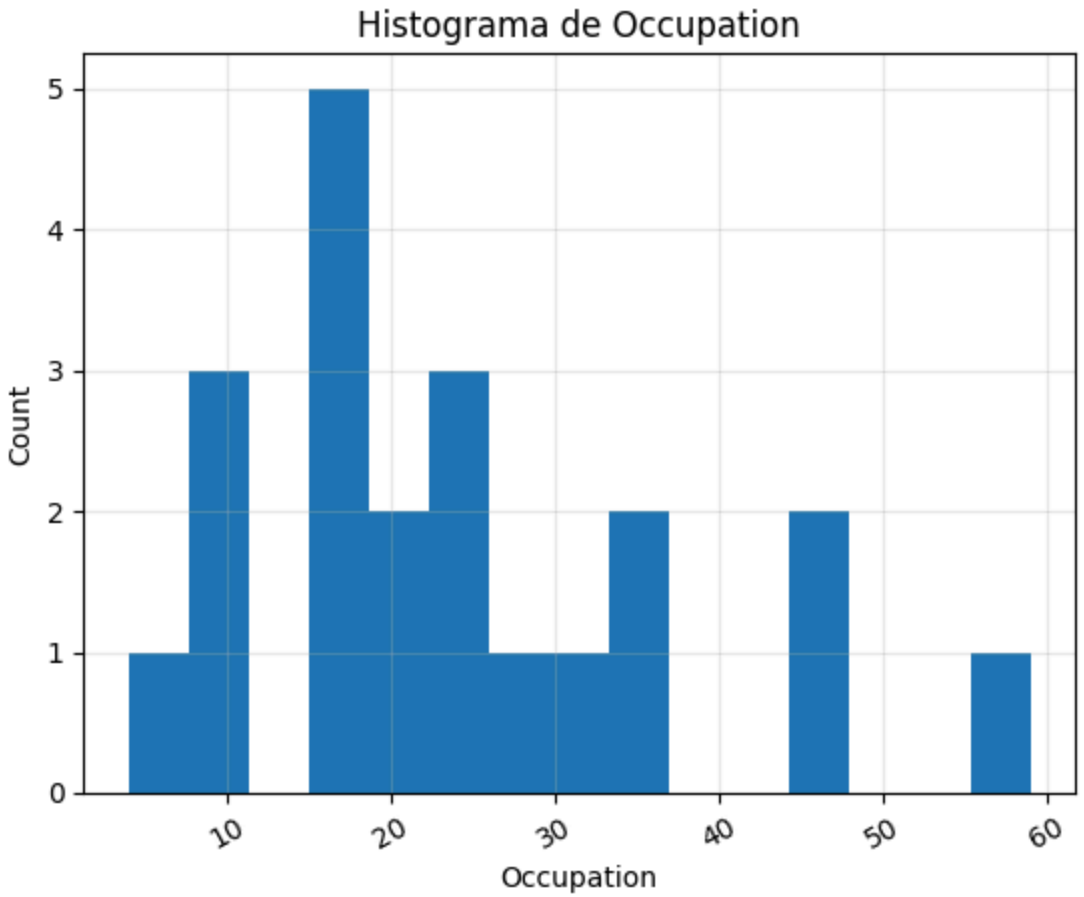
data_thursdays_9am_first
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot
0	0210202540135895219200	68de243386761436bc868b1e	2025-10-02	09:02:08.0500000	9
1	2108202540135895218982	68a6c584c8fbb8531ef9808e	2025-08-21	09:03:38.9830000	9
2	30102025401358152637	69031c9786761436bcb35eba	2025-10-30	09:00:47.8040000	9
3	250920254013581529894	68d4ea2486761436bc356863	2025-09-25	09:00:29.4510000	9
4	170720254013582329331	6878a35ae889950da1fb05cb	2025-07-17	09:11:16.8610000	9
5	201120254013582521678 7	691ecf1c86761436bc5f336e	2025-11-20	09:17:21.6090000	9
6	180920254013586321433	68cbb10d86761436bce3c2be	2025-09-18	09:09:11.5850000	9
7	161020254013582521678 7	68f09c1186761436bc25b038	2025-10-16	09:11:03.1800000	9
8	100720254013537521678 7	686f68efe889950da1b18c27	2025-07-10	09:03:09.9410000	9
9	07082025401358472149 1	68945389c8fbb8531e7ffcd0	2025-08-07	09:12:09.0860000	9
10	091020254013567528400	68e761e486761436bcd6a22b	2025-10-09	09:04:59.5030000	9
11	131120254018754521907 6	6915948586761436bc24c136	2025-11-13	09:07:19.7830000	9
12	040920254013581521749 4	68b93d7f86761436bc508bff	2025-09-04	09:12:16.2660000	9
13	06112025401357852637	690c5a7886761436bcee753e	2025-11-06	09:15:26.5560000	9
14	280820254013584722214	68b0038486761436bc0f52b1	2025-08-28	09:12:30.0940000	9
15	240720254013577321875 6	6881dfbfe889950da1439a41	2025-07-24	09:11:59.0930000	9
16	110920254013506321433	68c278f386761436bc96f0a5	2025-09-11	09:14:48.6970000	9
17	03072025401358632713	686630f2e889950da1648031	2025-07-03	09:12:45.4510000	9

	TripId	IdExternal	EventDate	EventTime	TimeSlot
18	310720254013577328192	688b1b41e889950da186fbda	2025-07-31	09:12:52.7840000	9
19	14082025401358372713	689d91abc8fbb8531ebe7c3e	2025-08-14	09:33:03.3770000	9
20	231020254013581327585	68f9dab686761436bc7467d2	2025-10-23	09:32:27.3050000	9

21 rows × 25 columns

```
histogram(data_thursdays_9am_first, "Occupation")
```




```
is_normal(data_thursdays_9am_first["Occupation"])
```

```
-Para 21 valores, con valor skewness: 0.9280915297380827 y kurtosis: 0.26674756345255
8,

-Con valores de SE, SE_skewness: 0.5345224838248488, SE_kurtosis: 1.0690449676496976,

-Se obtienen los siguientes valores de Z; Z_skew: 1.7363002639234122 y Z_kurtosis: 0.
24951949779905358,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: True

La distribución presenta una media:  24.476190476190474 y una desviación estandar σ:
13.411505535383549

-El comportamiento general de esta distribución es:
        -Cola derecha más grande que izquierda
        -Distribución leptocúrtica(picos más altos de lo normal)
```

```
outliers_thursday = estimate_outliers(data_thursdays_9am_first["Occupation"].tolist()
```

```
H_0:    There are No outliers
H_a:    There are up to 5 outliers in the data

Significance level : 0.05
Critical Region: Reject H_0 if R_i > Critical value

Summary Table for EDC Test
-----------------------------------------------------------
 Exact              Test                        Critical
Number of           Statistic                   Value, λ
Outliers, i         Value, R_i                     5%
-----------------------------------------------------------
        1                       2.512155562539791                       2.61996363983
44386
        2                       2.1032619377948487                      2.58567634067
19616
        3                       2.3829953189025077                      2.54830777174
33393
        4                       1.8627061026608094                      2.50732085257
88404
        5                       1.8928230657920817                      2.46203286854
26998
```

```
data_fridays = dataset[dataset["Weekday"] == "V"]

data_fridays = data_fridays[data_fridays["DayType"] == "LA"]

data_fridays_9am = data_fridays[data_fridays["TimeSlot"] == 9]

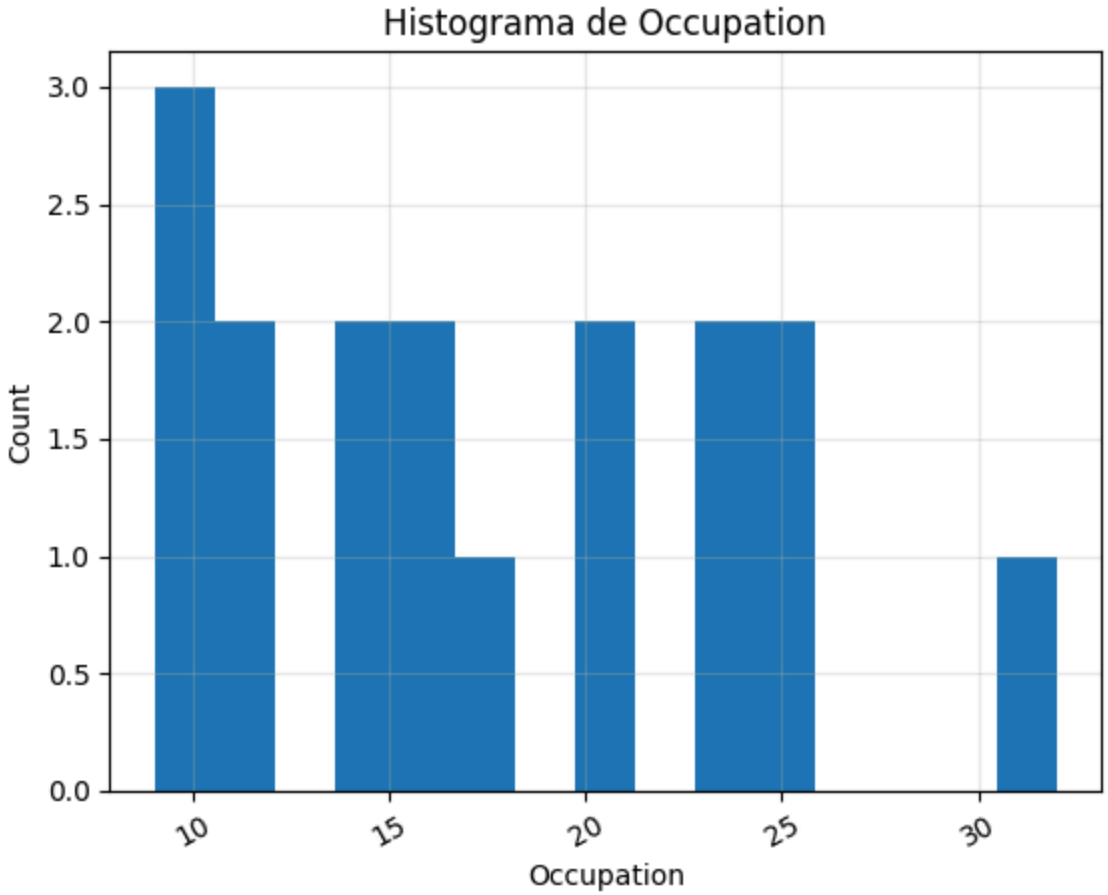
data_fridays_9am_first = extract_first_value(data_fridays_9am)

data_fridays_9am_first
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot
0	2908202540135905217875	68b1526386761436bc191a72	2025-08-29	09:03:22.2410000	9
1	040720254013545521678 7	68677f7ce889950da17091fd	2025-07-04	09:01:38.9820000	9
2	110720254013567521368 8	6870ba4de889950da1bde8d8	2025-07-11	09:06:04.7450000	9
3	22082025401358472226 1	68a819ddc8fbb8531e037843	2025-08-22	09:01:48.1550000	9
4	17102025401357852949 2	68f1ecc986761436bc32939b	2025-10-17	09:07:32.1420000	9
5	101020254013553521727 9	68e8b31886761436bce375e9	2025-10-10	09:01:10.6200000	9
6	19092025401358252897 5	68cd031886761436bcf0d5f4	2025-09-19	09:03:33.7280000	9
7	12092025401358852949 2	68c3c95386761436bca20fec	2025-09-12	09:01:24.5700000	9
8	01082025401358472149 1	688c6a24e889950da1919ed5	2025-08-01	09:03:41.0130000	9
9	26092025401351852905 0	68d63eb386761436bc42cc2e	2025-09-26	09:12:26.7320000	9
10	14112025401357652966 6	6916e5bf86761436bc2ddabe	2025-11-14	09:08:09.7790000	9
11	08082025401357772149 1	6895a547c8fbb8531e89eb95	2025-08-08	09:10:21.8360000	9
12	18072025401357732906	6879f65ee889950da106703f	2025-07-18	09:13:13.5410000	9
13	05092025401358532758 5	68ba8feb86761436bc5bce01	2025-09-05	09:09:52.0030000	9
14	24102025401358732143 3	68fb2a1586761436bc7ff3fc	2025-10-24	09:11:50.9150000	9
15	31102025401358232758 5	6904733386761436bcbcfce9	2025-10-31	09:18:39.4040000	9
16	07112025401358352221 4	690dafed86761436bcf7d908	2025-11-07	09:30:19.0520000	9

17 rows × 25 columns

```
histogram(data_fridays_9am_first, "Occupation")
```




```
is_normal(data_fridays_9am_first["Occupation"])
```

```
-Para 17 valores, con valor skewness: 0.4110184934718225 y kurtosis: -0.7405705282374
422,

-Con valores de SE, SE_skewness: 0.5940885257860046, SE_kurtosis: 1.1881770515720091,

-Se obtienen los siguientes valores de Z; Z_skew: 0.6918472174294689 y Z_kurtosis: -
0.623282975594955,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: True

La distribución presenta una media:  17.764705882352942 y una desviación estandar σ:
6.467378883239883

-El comportamiento general de esta distribución es:
        -Cola derecha más grande que izquierda
        -Distribución platicúrtica(distribución más achatada de lo normal)
```

```
outiers_fridays = estimate_outliers(data_fridays_9am_first["Occupation"].tolist(), 5,
```

```
H_0:    There are No outliers
H_a:    There are up to 5 outliers in the data

Significance level : 0.05
Critical Region: Reject H_0 if R_i > Critical value

Summary Table for EDC Test
-----------------------------------------------------------
 Exact              Test                        Critical
Number of           Statistic                   Value, λ
Outliers, i         Value, R_i                     5%
-----------------------------------------------------------
        1                       2.1353726254367666                      2.46203286854
26998
        2                       1.4133106699959344                      2.41155951843
16536
        3                       1.5723578790769954                      2.35473005156
5537
        4                       1.6087257627431644                      2.28995408447
961
        5                       1.8779423687366343                      2.21500422332
5564
```

Concluidas todas las ejecuciones podemos ver ciertas cosas:

- Todos los días, la hipótesis de normalidad es asumida como cierta.
- La media de las distribuciones de los días oscila entre 16~17 y 24 y la desviación típica entre 6 y 13.
- Hay un día, en concreto el jueves, que presenta 3 valores que, aunque no son reconocidos como outliers, conviene analizar, ya que son 3 díaas con valor de ocupación >45, lo cual puede ser indicio de un caso especial, o al menos de interés

Vamos a ver esos datos de los jueves en concreto.

```
outliers_thursday
```

```
[(59, np.float64(2.512155562539791)),
 (47, np.float64(2.1032619377948487)),
 (46, np.float64(2.3829953189025077)),
 (4, np.float64(1.8627061026608094)),
 (36, np.float64(1.8928230657920817))]
```

```
data_outliers_thursday = data_thursdays_9am_first[data_thursdays_9am_first["Occupatio
data_outliers_thursday
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot	Li
0	0210202540135895219200	68de243386761436bc868b1e	2025-10-02	09:02:08.0500000	9	4
2	30102025401358152637	69031c9786761436bcb35eba	2025-10-30	09:00:47.8040000	9	4
6	180920254013586321433	68cbb10d86761436bce3c2be	2025-09-18	09:09:11.5850000	9	4

3 rows × 25 columns

No parece haber un factor que correlacione estos días concretos, ya que puedes agrupar 2 de ellos por temperatura similar y el otro por probabilidad de lluvia mayor a 30. Hay que tener algo en cuenta de este análisis, y es: Estamos seleccionando la instancia de cada día en concreto que más cerca tiene su valor EventTime(El de la tabla Master) de las 9 am, ya que está la query ordenada por Mbot.EventTime. Esto nos puede dejar en que estos días en concreto el bus anterior acumulara muy poca demanda y este bus quede con un número mayor al "normal". Esto entra dentro de las posibilidades.

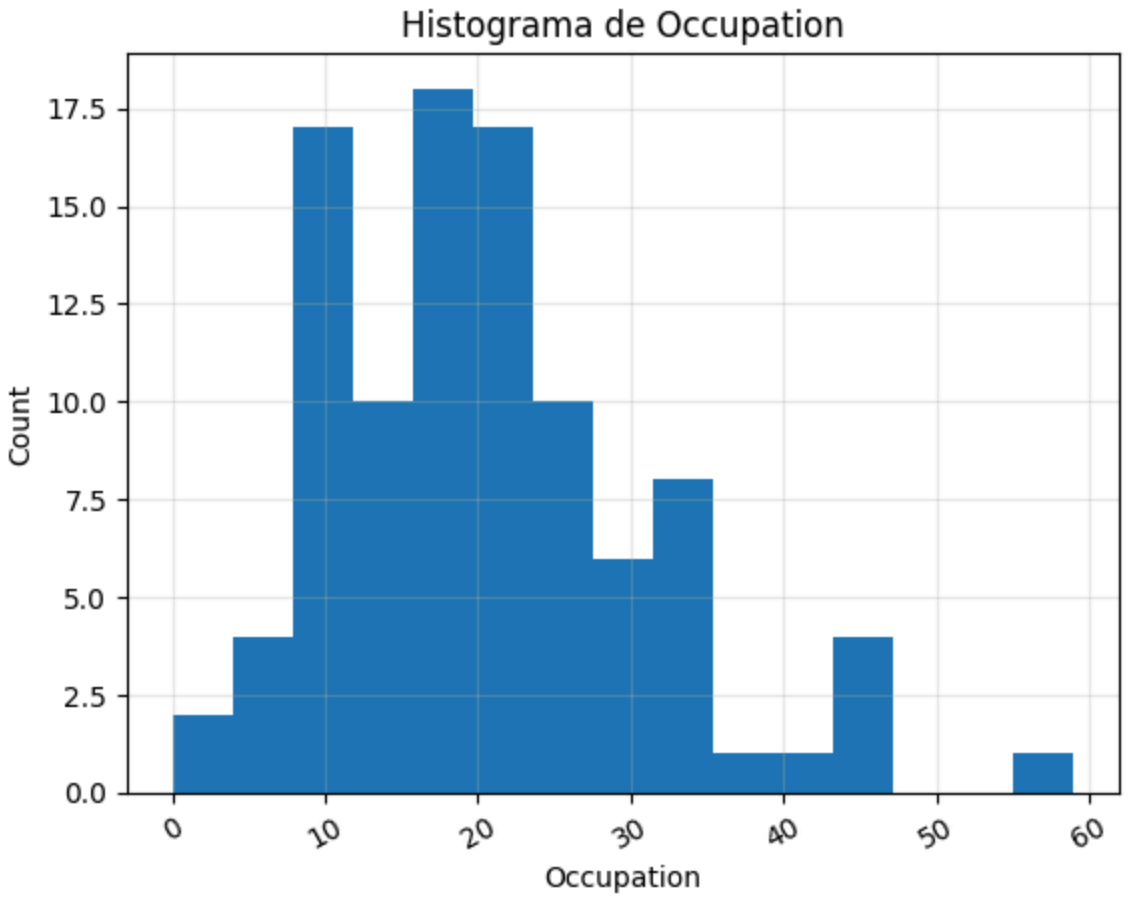
Ahora bien, podemos, obviando estos casos que de momento no son explicables, asumir que los días laborables en la franja de las 9 de la mañana siguen la misma distribución de probabilidad, y esta puede ser una normal? Vamos a comprobarlo. Para ello, seleccionaremos todos los "primeros" datos que tenemos de cada día y realizaremos los mismos tests.

```
data_9_am = dataset[dataset["DayType"] == "LA"]
data_9_am = data_9_am[data_9_am["TimeSlot"] == 9]
data_9_am_first = extract_first_value(data_9_am)
data_9_am_first
```

	TripId	IdExternal	EventDate	EventTime	TimeSlot
0	08102025401358152637	68e60ce486761436bcc99218	2025-10-08	09:01:57.5970000	9
1	0210202540135895219200	68de243386761436bc868b1e	2025-10-02	09:02:08.0500000	9
2	130820254013589529331	689c3985c8fbb8531eb46b39	2025-08-13	09:00:56.7670000	9
3	2108202540135895218982	68a6c584c8fbb8531ef9808e	2025-08-21	09:03:38.9830000	9
4	30102025401358152637	69031c9786761436bcb35eba	2025-10-30	09:00:47.8040000	9
...	...	...	...	...	...
94	231020254013581327585	68f9dab686761436bc7467d2	2025-10-23	09:32:27.3050000	9
95	20082025401358372713	68a57b31c8fbb8531eefe5cb	2025-08-20	09:27:22.0980000	9
96	071120254013583522214	690dafed86761436bcf7d908	2025-11-07	09:30:19.0520000	9
97	100920254013579722261	68c1311786761436bc8c52d7	2025-09-10	09:55:41.8360000	9
98	29102025401358452713	6901d8bd86761436bcaac5cf	2025-10-29	09:57:43.7610000	9

99 rows × 25 columns

```
histogram(data_9_am_first, "Occupation")
```




```
is_normal(data_9_am_first["Occupation"])
```

```
-Para 99 valores, con valor skewness: 0.8610048703994452 y kurtosis: 1.12444426163562
92,

-Con valores de SE, SE_skewness: 0.24618298195866548, SE_kurtosis: 0.4923659639173309
5,

-Se obtienen los siguientes valores de Z; Z_skew: 3.4974183168518502 y Z_kurtosis: 2.
283757091350094,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: False

La distribución presenta una media:  20.474747474747474 y una desviación estandar σ:
10.726483259579965

-El comportamiento general de esta distribución es:
        -Cola derecha más grande que izquierda
        -Distribución leptocúrtica(picos más altos de lo normal)
```

```
outliers_weekday = estimate_outliers(data_9_am_first["Occupation"].tolist(), 10, 0.05
```

```
H_0:    There are No outliers
H_a:    There are up to 10 outliers in the data

Significance level : 0.05
Critical Region: Reject H_0 if R_i > Critical value

Summary Table for EDC Test
-----------------------------------------------------------
 Exact              Test                        Critical
Number of           Statistic                   Value, λ
Outliers, i         Value, R_i                     5%
-----------------------------------------------------------
       1                       3.5734159812227744                    3.34773781782
1611 *
       2                       2.6656729510106527                    3.34383558090
3338
       3                       2.7842488230471107                    3.33987968775
84758
       4                       2.813957665391415                     3.33586874110
18204
       5                       2.9557912076940425                    3.33180129006
863
       6                       2.5443740396840924                    3.32767582749
12073
       7                       2.229101504627256                     3.32349078700
26715
       8                       2.1830570903543376                    3.31924453995
45845
       9                       2.1008513958857007                    3.31493539213
33127
       10                      2.0398034212540836                    3.31056158026
02855
```

```
outliers_weekday[0]
```

```
(59, np.float64(3.5734159812227744))
```

Hecho este análisis podemos ver lo siguiente. Se **RECHAZA** la hipótesis de normalidad de los datos, al superar la Z_skew el valor de Z_score que se utiliza como baremo. El test de outliers indica(aunque el test en principio aplica a datos aparentemente "normales") que el número estimado de outliers es de 1, siendo este el valor máximo de la distribución.

Esto nos da varias preguntas. Es este "dato atípico" que hemos visto antes, aparentemente sin ningún parámetro asociado a ese día que sea fuera de lo normal, el que nos está fastidiando la normalidad?

```
data_9_am_first = data_9_am_first[data_9_am_first["Occupation"] <= 58]

is_normal(data_9_am_first["Occupation"])
```

```
-Para 98 valores, con valor skewness: 0.6006796663645062 y kurtosis: 0.29269940693037
233,

-Con valores de SE, SE_skewness: 0.24743582965269675, SE_kurtosis: 0.494871659305393
5,

-Se obtienen los siguientes valores de Z; Z_skew: 2.4276179695059756 y Z_kurtosis: 0.
59146528484013,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: True

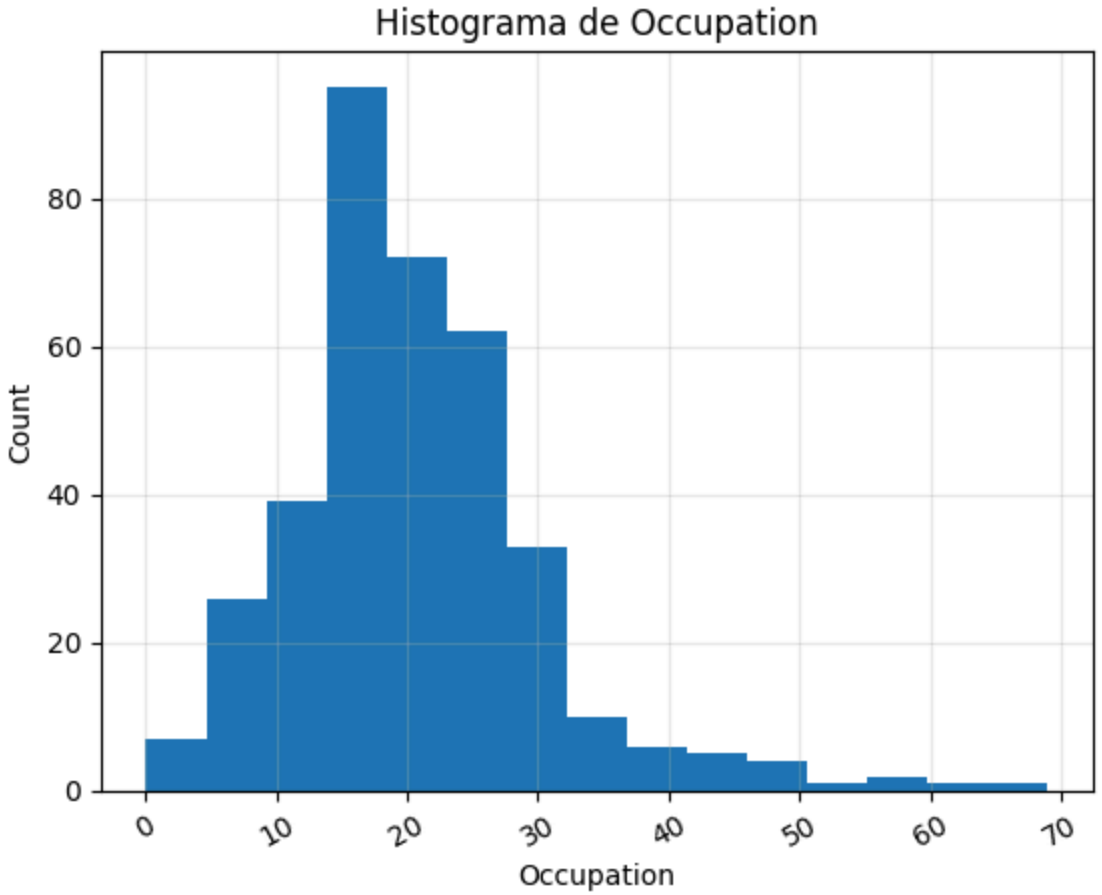
La distribución presenta una media:  20.081632653061224 y una desviación estandar σ:
10.046497480224554

-El comportamiento general de esta distribución es:
        -Cola derecha más grande que izquierda
        -Distribución leptocúrtica(picos más altos de lo normal)
```

Si eliminamos ese valor, obtenemos que la hipótesis de la normalidad se asume, con media ~~20 y desviación estandar 10.04, aunque también, gracias al tipo de test que estamos realizando, tenemos más información sobre los datos. Entre ellos, la cola derecha es más grande de la izquierda, y se presentan picos más altos que de normal, lo cual siempre es bueno saberlo

Si por ejemplo ahora eliminamos el criterio de "first" que estabamos cogiendo para cada día, es decir, ya no vamos a tener en cuenta únicamente el dato más cercano a las 9 por día, si no todos los datos cuyo timeSlot sea las 9. La distribución resultante será también normal?? Tendrá valores de media y desviación típica similares??? Vamos a verlo

```
histogram(data_9_am, "Occupation")
```




```
is_normal(data_9_am["Occupation"])
```

```
-Para 364 valores, con valor skewness: 1.3033672229703919 y kurtosis: 3.5975457413296
6,

-Con valores de SE, SE_skewness: 0.12838814775327387, SE_kurtosis: 0.2567762955065477
4,

-Se concluye por lo tanto que la hipótesis de que la distribución es normal es: True

La distribución presenta una media:  20.546703296703296 y una desviación estandar σ:
9.560996494451416

-El comportamiento general de esta distribución es:
        -Cola derecha más grande que izquierda
        -Distribución leptocúrtica(picos más altos de lo normal)
```

```
outliers_weekday_no_first_restr = estimate_outliers(data_9_am["Occupation"].tolist(),
```

```
H_0:    There are No outliers
H_a:    There are up to 15 outliers in the data

Significance level : 0.05
Critical Region: Reject H_0 if R_i > Critical value

Summary Table for EDC Test
-----------------------------------------------------------
 Exact              Test                        Critical
Number of           Statistic                   Value, λ
Outliers, i         Value, R_i                     5%
-----------------------------------------------------------
       1                       5.060842165374695                      3.76664565105
3998 *
       2                       4.607965286291881                      3.76585394510
19055 *
       3                       4.310795534517082                      3.76505966661
7421 *
       4                       4.3184562364017705                     3.76426279949
3018 *
       5                       3.6213905901613876                     3.76346332747
026
       6                       3.218025813122943                      3.76266123414
1445
       7                       3.270284678712829                      3.76185650294
53856
       8                       3.202719968617713                      3.76104911716
66003
       9                       3.2545655422483444                     3.76023905993
27253
       10                      3.1832028252202496                     3.75942631421
34867
       11                      2.97948983904724                       3.75861086281
7888
       12                      3.022045810854176                      3.75779268839
26085
       13                      2.9360226556447153                     3.75697177342
00845
       14                      2.977079962931501                      3.75614810021
59676
       15                      2.886488040733559                      3.75532165092
7375
```

```
outliers_weekday_no_first_restr[0:4]
```

```
[(69, np.float64(5.060842165374695)),
 (63, np.float64(4.607965286291881)),
 (59, np.float64(4.310795534517082)),
 (58, np.float64(4.3184562364017705))]
```

Sobre la no restriccion de un dato por día nos encontramos que la normalidad también es aceptada como hipótesis, con valores de media y desviación estandar muy similares a lo anterior. También los valores de skewness y kurtosis son igualmente interpretables.

El test de outliers lanza como outliers los valores más altos, los cuales son 69,63,59 y 58, lo cual cuadra con la anterior distribución(Que de hecho tuvimos que quitarle el valor de 59 porque si no la hipótesis de normalidad no se cumplía).

Siguientes Avances

Ahora bien. Una vez concluido este análisis de la franja horaria para los días laborables nos quedan las siguientes preguntas o casos particualres por hacernos:

- Los valores extremos que hemos notado para ciertos días los cuales no podían tener una explicación como pudiera ser dias con gratuidad, valores de temperatura muy extremos, etc. Existe un motivo por el cuál se produce ese valor tan elevado de ocupación o es simplemente la casuística del problema.
- Este análisis es replicable a festivos, domingos o días no lectivos?
- Notaremos diferencias si analizamos en profundidad días con gratuidad? Hay suficientes para tener una muestra significativa?
- Lo mismo que la anterior pero aplicable a otros filtros.