uc3m | Universidad Carlos III de Madrid

Grado Universitario en Ingeniería Informática

2025-2026

Trabajo Fin de Grado

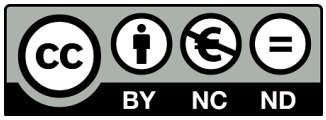
“Sistema Multi-Agente de simulación de autobuses para evaluación de la dotación programada mediante Kpis”

Héctor Álvarez Marcos

Tutor/es

Javier Ignacio Carbó Rubiera

Lugar y fecha de presentación prevista



Esta obra se encuentra sujeta a la licencia Creative Commons **Reconocimiento - No Comercial - Sin Obra Derivada**

RESUMEN

RESUMEN RESUMEN RESUMEN

Palabras clave: Agentes Inteligentes, KPI, Simulación de Monte Carlo, GAMA

AGRADECIMIENTOS

ÍNDICE GENERAL

1. INTRODUCCIÓN. 1
2. ESTADO DEL ARTE 3
2.1. Agentes Inteligentes 3
2.1.1. Definición 3
2.1.2. Taxonomía 6
2.1.3. Contexto histórico y evolución 8
2.1.4. Comunicación 9
2.1.5. Plataformas de Desarrollo 10
2.1.6. Viabilidad de la solución utilizando Agentes Inteligentes 10
2.2. Simuladores de Transporte 11
2.2.1. Técnicas de simulación 11
2.2.2. Sistemas Multi-Agente como simuladores 14
2.2.3. Simulaciones de Monte Carlo 15
2.2.4. Análisis estadístico de datos. 16
3. METODOLOGÍA 23
3.1. Definición del problema 23
3.2. Estructura de trabajo 24
3.3. Herramientas Utilizadas 27
3.4. Extracción de KPIs. 28
3.4.1. Métricas a nivel general 28
3.4.2. Métricas a nivel de autobús 29
3.4.3. Métricas a nivel de ruta 29
4. ANÁLISIS DE LOS DATOS 31
4.1. Limpieza y preparación 31
4.1.1. Datos geoespaciales 31
4.1.2. Datos de Operación 33
4.2. Estudio y Gaussianidad 37
4.2.1. Estudio de viabilidad de datos operacionales 38

4.3. Preparación para Simulador 39
4.3.1. Estudio y análisis de carga, descarga y tiempo entre paradas 39
4.3.2. Adaptación de formato de parámetros de entrada 39
5. DISEÑO DE LA SIMULACIÓN 41
6. CASOS DE APLICACIÓN. 42
7. MARCO REGULADOR 43
8. PRESUPUESTO Y COSTES 44
9. TRABAJOS FUTUROS 45
10. CONCLUSIÓN 46
BIBLIOGRAFÍA 47

ÍNDICE DE FIGURAS

2.1 Representación conceptual de un agente y el entorno en el que se encuentra 6

2.2 Evolución histórica del paradigma de agentes inteligentes 9

2.3 Evolución de convergencia relativa a parámetro de Monte Carlo 16

2.4 Representación de la distribución normal o de Gauss ($\mu = 0$, $\sigma = 1$) . . . 17

2.5 Representación de la distribución binomial negativa ($r = 5$, $p = 0{,}4$) . . . 19

2.6 Representación de la distribución geométrica ($p = 0{,}3$) 19

3.1 Diagrama de Gantt explicativo relativo a las distintas fases del desarrollo . 26

3.2 Fórmula de regularidad para cada caso concreto de aplicación 29

4.1 Visualización en QGIS del mapa geoespacial convertido a shapefile . . . 32

4.2 Visualización en GAMA de los shapefile transformados 32

4.3 Modelo Master:Transaccional de la base de datos 34

ÍNDICE DE TABLAS

2.1 Comparativa de plataformas de desarrollo de sistemas multiagente 10

4.1 Parámetros de la tabla Master 35

4.2 Parámetros de la tabla Transaccional 36

1. INTRODUCCIÓN

El estudio, gestión y análisis de movilidad urbana en grandes ciudades es uno de los mayores desafíos para las empresas públicas y privadas dentro del sector de transportes. Gracias a la evolución tecnológica en los últimos años, estas empresas se han visto obligadas a adaptarse a los nuevos entornos digitales, buscando nuevos métodos de análisis y cómputo que les permitan mantener una posición más competitiva y obtener resultados mucho más fiables y accesibles en tiempos más cortos. Ejemplos como Pelletier et al. [1] muestran cómo los datos de las tarjetas inteligentes son usados para el estudio de la movilidad a tres niveles: estratégico, táctico y operacional. Otro ejemplo es el realizado por Nesmachnow y Hernández [2], el cual presenta un estudio hecho en Uruguay sobre implementación de Big Data para analizar el sistema de transporte público de Montevideo. Estos estudios ilustran cómo la adopción de nuevas tecnologías es un hecho creciente en el ámbito del transporte.

En el contexto del problema se sitúa la Empresa Municipal de Transportes de Madrid (EMT)[1], operador del servicio de autobuses urbanos de la capital española. En los últimos años, ha impulsado múltiples iniciativas de innovación tecnológica, destacando «Madrid Green Urban Mobility Lab» o la inclusión del sistema «Galileo». La primera es una iniciativa sin ánimo de lucro que busca promover la movilidad urbana sostenible[2]. «Galileo», por su parte, es un sistema europeo de navegación por satélite, incorporado en la totalidad de la flota con el fin de mejorar la precisión del posicionamiento de los buses[3]. En el contexto de este trabajo, se busca mejorar el análisis del servicio prestado para sus líneas de autobús. Para ello, la Empresa Municipal plantea validar la viabilidad de construir una herramienta que permita extraer la información relevante sobre el desempeño de la flota de autobuses a lo largo de una línea específica.

En este trabajo se propone una implementación de software basada en agentes inteligentes que permite simular el comportamiento de los de autobuses para una línea concreta. Este sistema permite extraer distintas métricas de rendimiento (KPI, del inglés *Key Performance Indicators*). El simulador recibe distintos parámetros de entrada derivados de un estudio realizado sobre datos reales de operación de una línea a lo largo de ocho meses de servicio. Esta base permite al usuario final del sistema evaluar estos escenarios a partir de evidencias empíricas, con el objetivo último de otorgar una herramienta que pueda servir

[1] https://www.emtmadrid.es(accedido: 6 de mayo de 2026)

[2] EMT Madrid, «*Madrid Green Urban Mobility Lab* convertirá a la capital en un referente internacional en innovación y tecnología de la movilidad», 26 de septiembre de 2022. Disponible en: https://www.emtmadrid.es/Noticias/%E2%80%98Madrid-Green-Urban-Mobility-Lab%E2%80%99-convertira-a-la.aspx(accedido: 6 de mayo de 2026).

[3] EU Agency for the Space Programme (EUSPA), «EMT Madrid announces readiness to Galileo in all the metropolitan bus fleet», 19 de abril de 2019. Disponible en: https://www.euspa.europa.eu/newsroom-events/news-archive/emt-madrid-announces-readiness-galileo-all-metropolitan-bus-fleet(accedido: 6 de mayo de 2026).

para mejorar la eficiencia en la planificación diaria de autobuses. Para facilitar la usabilidad del sistema, se ha levantado el simulador sobre una interfaz web, que permite tanto la personalización de las simulaciones, como la visualización de las distintas estadísticas resultantes.

A lo largo de este documento, se presentan, discuten y valoran las distintas decisiones de diseño, así como los retos enfrentados, y las conclusiones obtenidas del trabajo. En el capítulo segundo del documento, se discute acerca del estado de la cuestión, en el que se analizan diversas soluciones existentes en la literatura acerca del problema y cómo han ido evolucionando los distintos conceptos clave a lo largo del tiempo. Seguidamente, el capítulo tercero trata la metodología de trabajo escogida, junto a la explicación detallada sobre cada uno de los pasos. COMPLETARË A LA QUE SIGA AÑADIENDO COSAS A LA MEMORIA

2. ESTADO DEL ARTE

En este capítulo se expone una revisión analítica de la literatura existente relevante para el problema abordado en este trabajo. La revisión se organiza en torno a los principales ejes del desarrollo de la solución, ahondando en cómo se resuelven los distintos problemas existentes en cada eje y cómo se diferencia la implementación realizada.

2.1. Agentes Inteligentes

2.1.1. Definición

Existen muchas acepciones de lo que es un agente inteligente dentro de la literatura, entre ellas, una de las más citadas, Maes [3, p. 139], los define como «Los agentes autónomos son sistemas computacionales que habitan en un ambiente dinámico complejo, sienten y actúan autónomamente en ese entorno y al hacerlo llevan a cabo un conjunto de objetivos o tareas para las que fueron diseñados.»[4]

Otra definición muy citada en la literatura y ampliamente reconocida es de Jennings y Wooldridge [4, p. 4], «Un agente es un sistema computacional situado en un entorno, y que es capaz de realizar acciones autónomas en este con el fin de cumplir sus objetivos de diseño»[5]

Ambas definiciones comparten puntos comunes, como la especificación de que un agente es un **sistema computacional** y que buscan cumplir una serie de objetivos y tareas para las que fueron diseñados[3], [4]. Dentro de los distintos conceptos a discutir sobre agentes, se pueden subdividir estos dentro de dos grupos principales: **Características del Entorno** y **Características propias del elemento agente**. En la figura 2.1 se muestra una representación gráfica de los conceptos principales de cada uno de los dos grupos. A continuación se exponen y discuten las diferentes características de estos.

- **Capacidades del entorno**

  La definición formal de Jennings y Wooldridge no especifica características propias del entorno, pero en párrafos posteriores, rechaza la hipótesis de llamar agentes inteligentes a aquellos que se desarrollen en escenarios que no requieran **flexibilidad** y **complejidad**, utilizando como ejemplo comparativo el sistema autónomo de un termostato[4]. Por otra parte, Maes [3] sí que explícitamente caracteriza el ambiente

[4]Traducción del original: «*Autonomous agents are computational systems that inhabit some complex, dynamic environment, sense and act autonomously in this environment, and by doing so realize a set of goals or tasks for which they are designed*».

[5]Traducción del original: «*an agent is a computer system situated in some environment, and that is capable of autonomous action in this environment in order to meet its design objectives*».

como uno dinámico y complejo dentro de la definición de agente. Esto lleva a poder remarcar que no es adecuado, relativo a cuestiones meramente formales, referirse a un sistema que no tiene un entorno caracterizado por su dinamismo y complejidad como un sistema apto para incluir una solución basada en agentes inteligentes.

Otro tema que se define como base que es imperioso remarcar en la revisión literaria es el de la **capacidad distribuida del conocimiento**. Tanto Maes, que especifica que los agentes son creados como pequeños expertos en un tema concreto y que se crean de forma distribuida[3], como Jennings y Wooldridge, los cuales mencionan que una característica que se puede tener en consideración del dominio en el cual se puede aplicar una solución basada en agentes es la existencia del conocimiento de forma distribuida[4]. Al explorar otros artículos en los que se mencione dicha característica, como puede ser la revisión literaria sobre agentes realizada por Nwana, se observa que se incluye como una de las motivaciones para construir un sistema de agentes el solucionar problemas inherentemente distribuidos[5]. Esto permite trazar un consenso generalizado sobre esta característica de los dominios en los que los agentes trabajan.

- **Características propias del elemento agente**.

  Con respecto a la caracterización propia de los agentes, resulta necesario analizar de forma sistemática las distintas propiedades que los definen. A continuación, se presentan las principales características basadas en la arquitectura de los agentes de Wooldridge y Jennings [6], detallando cada una de ellas:

  - **Autonomía**: Discutida ampliamente por Castelfranchi [7] en 1995, incluye varias cuestiones a destacar. Primeramente, una definición débil de autonomía puede postularse como la capacidad de completar una tarea u objetivo concreto sin necesidad de interacción humana[7]. Para fortalecer la definición, resulta imperioso profundizar en las diferentes características necesarias para considerar autonomía real, ya que un concepto de autonomía tan simple como el autocompletado de tareas sin interacción da paso a posibles malinterpretaciones. El mismo Castelfranchi presenta un concepto como el de «Autonomía ejecutiva» para referirse a aquella autonomía que carece de capacidad de toma de decisiones, que se limita a seguir una serie de instrucciones u órdenes sin preferencias personales. Esta subcategoría permite encapsular y diferenciar la autonomía a dos niveles. En la capa inferior está esa «autonomía ejecutiva», que permite al agente resolver tareas sin intervencionismo humano, pero para presentar completa autonomía, hace falta una capa superior que presente «racionalidad». Esta hace referencia a la capacidad de los agentes de tomar decisiones de adopción o rechazo de ideas basada en sus objetivos. Se especifica que ambas ideas deben coexistir para que haya **autonomía completa**. La falta de alguna de ellas reduce las capacidades autónomas del agente en cuestión.

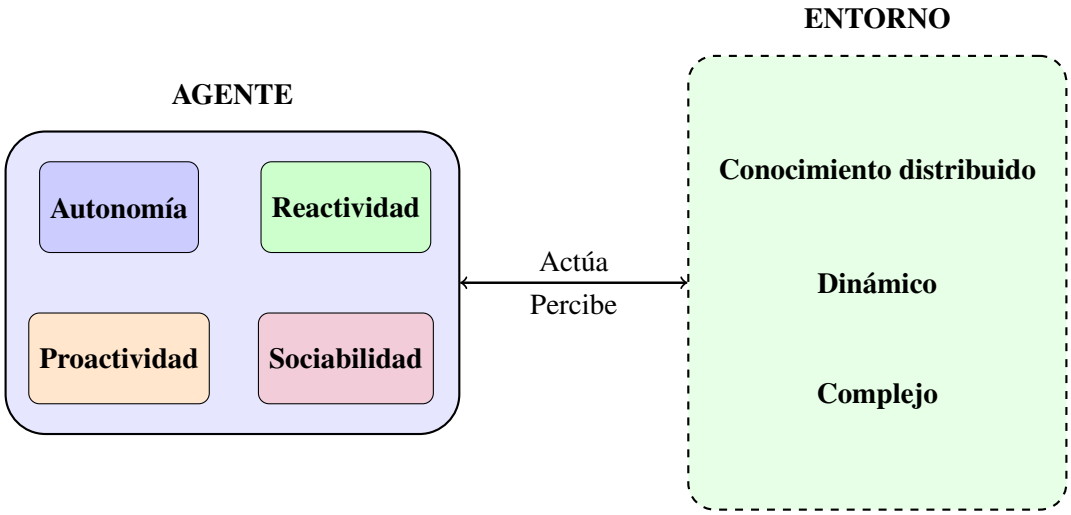
- **Reactividad**: La reactividad se define como la capacidad de un agente de percibir su entorno y responder de forma oportuna a los cambios que se producen en él [6]. Esta propiedad implica que el agente no opera de forma aislada respecto a su entorno, sino que mantiene una vinculación continua con él: percibe estímulos y genera respuestas adecuadas en función de las condiciones observadas. El fundamento teórico de la reactividad tiene su origen en el trabajo de Brooks [8], quien propuso la denominada *arquitectura de subsunción* (*subsumption architecture*). En dicha arquitectura, el comportamiento inteligente emerge de la interacción de capas de control simples con el entorno, sin necesidad de mantener un modelo simbólico interno del mundo. Cada capa vincula directamente la percepción con la acción mediante reglas estímulo-respuesta, lo que permite al sistema operar en entornos dinámicos con tiempos de respuesta reducidos [8]. Este enfoque supuso una ruptura con los paradigmas deliberativos de la inteligencia artificial clásica, en los que la toma de decisiones dependía de un proceso de razonamiento simbólico previo a la acción. No obstante, como señalan Wooldridge y Jennings [6], la reactividad por sí sola no es suficiente para caracterizar a un agente inteligente, ya que un sistema puramente reactivo carece de la capacidad de perseguir objetivos a largo plazo, lo que motiva la necesidad de la proactividad como propiedad complementaria.
- **Sociabilidad**: El término *sociabilidad*, definido por la RAE como «cualidad de sociable»[6], remite al concepto de *sociable*, que a su vez se define como «naturalmente inclinado al trato y relación con las personas o que gusta de ello»[7]. En el contexto de los sistemas multiagente, la sociabilidad se define como la capacidad de comunicación entre agentes mediante un lenguaje determinado[6], y representa el habilitador de la cooperación entre agentes. Según Nwana [5], esta cooperación es la razón de ser de la construcción de sistemas con múltiples agentes. Existen diferentes formas de comunicación, explicadas en profundidad en la sección 2.1.4.
- **Proactividad**: Esta propiedad se refiere a la capacidad de tomar la iniciativa y exhibir un comportamiento dirigido a objetivos [6, p. 116]. Un agente proactivo no se limita a reaccionar ante estímulos externos, sino que es capaz de actuar por iniciativa propia con el fin de satisfacer sus objetivos de diseño. Esta distinción es relevante porque, como señalan Wooldridge y Jennings [6], lograr un equilibrio adecuado entre comportamiento reactivo y proactivo constituye uno de los principales desafíos en el diseño de agentes inteligentes: un agente excesivamente reactivo puede ser incapaz de mantener un plan de acción coherente ante perturbaciones continuas del entorno, mientras que un agente excesivamente proactivo puede ignorar cambios relevantes en su en-

[6]Real Academia Española, *Diccionario de la lengua española*, 23.ª ed. https://dle.rae.es/sociabilidad(accedido: 6 de mayo de 2026)

[7]Real Academia Española, *Diccionario de la lengua española*, 23.ª ed. https://dle.rae.es/sociable(accedido: 6 de mayo de 2026)

torno por perseguir objetivos que han dejado de ser válidos. Franklin y Graesser [9] recogen esta propiedad bajo la denominación de *goal-oriented*, definiéndola como la capacidad del agente de no limitarse a actuar en respuesta al entorno, sino de perseguir activamente sus propios objetivos. En la práctica, la proactividad se manifiesta en la capacidad del agente de planificar, anticipar situaciones futuras o iniciar acciones sin que un estímulo externo inmediato las desencadene.

Además de estas cuatro propiedades, la literatura identifica otras características que definen subclases más específicas de los agentes, como la capacidad de aprendizaje, la movilidad o la continuidad temporal [9]. No obstante, las cuatro propiedades expuestas constituyen un núcleo comúnmente aceptado para la caracterización de agentes inteligentes [6].



Fuente: elaboración propia a partir de [3], [4], [6].

Fig. 2.1. Representación conceptual de un agente y el entorno en el que se encuentra

2.1.2. Taxonomía

En cuanto a la clasificación de los distintos tipos de agentes se pueden encontrar dos principales en la literatura.

La primera, basada en la arquitectura del sistema construido, presentada por Wooldridge y Jennings [6], expone tres principales pilares arquitectónicos para la clasificación de agentes:

- **Arquitectura Deliberativa**: Basada en los paradigmas de la IA simbólica, establece la construcción para cada agente de un modelo simbólico del mundo, en el que las decisiones se toman mediante razonamiento lógico derivado de esta concepción[6].

Esto genera un problema principal, cómo se traslada ese comportamiento del mundo real a un modelo simbólico. No existe un consenso generalizado, una fórmula que permita realizar esta proyección, sin embargo, existen varias implementaciones que abrazan este concepto de *arquitectura deliberativa*. La más popular se conoce como «arquitectura BDI»(**B**eliefs **D**esires **I**ntentions), fue formulada por Bratman [10] en 1987. Esta, construye un modelo simbólico del mundo real (Beliefs), que junto a una serie de objetivos a resolver (Desires), y unos planes seleccionados de la interacción del agente con el entorno (Intentions) crean un modelo de *agente inteligente* deliberativo

- **Arquitectura Reactiva**: Basada en el concepto de reactividad mencionado anteriormente, busca desligarse de la IA simbólica que caracteriza a la *Arquitectura deliberativa*. Brooks[11]-[13] propone que la inteligencia no tiene por qué presentarse como una representación simbólica, en contra de lo que la arquitectura deliberativa establece. Plantea que la inteligencia está situada en el mundo, y no fragmentada en sistemas expertos, generándose también por la interacción entre el agente y el entorno.

- **Arquitectura híbrida**: Propone un enfoque mixto que combina un subsistema reactivo, encargado de responder de forma inmediata a los cambios del entorno, con un subsistema deliberativo, responsable de la planificación y el razonamiento a largo plazo [6]. Entre las propuestas más influyentes se encuentra la arquitectura *TouringMachines* de Ferguson [14], basada en tres capas horizontales —reactiva, de planificación y de modelado— en las que cada capa tiene acceso independiente a la percepción y a la acción. Un enfoque alternativo es la arquitectura *InteRRaP* de Müller et al. [15], que emplea una estructura vertical por capas en la que únicamente la capa inferior percibe el entorno y únicamente la superior ejecuta acciones, reduciendo la competencia entre capas a costa de una mayor rigidez en el flujo de control. El objetivo de este tipo de arquitecturas es combinar la rapidez de respuesta del nivel reactivo con la capacidad de planificación del nivel deliberativo, buscando el equilibrio entre ambas propiedades que Wooldridge y Jennings [6] identifican como uno de los principales desafíos en el diseño de agentes inteligentes.

El segundo enfoque, enunciado por Franklin y Graesser [9], consiste en una clasificación inspirada en la taxonomía biológica, organizada como un árbol jerárquico en el que cada nivel representa una distinción basada en la naturaleza del agente. En el nivel superior, los agentes autónomos se clasifican en tres categorías: **biológicos** (seres humanos, animales), **robóticos** (robots físicos autónomos) y **computacionales** (entidades software). Los agentes computacionales se subdividen a su vez en **agentes software** orientados a tareas específicas, entretenimiento o seguridad y **agentes de vida artificial**, que habitan entornos simulados. Adicionalmente, los autores proponen que, independientemente de su posición en el árbol, los agentes pueden clasificarse según el **subconjunto de propiedades** que exhiben —reactividad, autonomía, orientación a objetivos, continuidad

temporal, sociabilidad, aprendizaje, movilidad, flexibilidad y personalidad—, de manera que la adición de propiedades define subclases cada vez más específicas [9]. Este enfoque complementa la clasificación arquitectónica de Wooldridge y Jennings [6], ya que permite caracterizar a un agente tanto por *cómo está construido* (arquitectura) como por *qué tipo de entidad es* (naturaleza) y *qué propiedades exhibe* (capacidades).

En la justificación de la arquitectura de los agentes escogida, se tiene en cuenta la taxonomía presentada por Wooldridge y Jennings [6], la cual permite identificar el tipo de arquitectura más adecuado en función de las características del dominio y de los requisitos del problema. Dicha justificación se desarrolla en el capítulo de diseño del sistema.

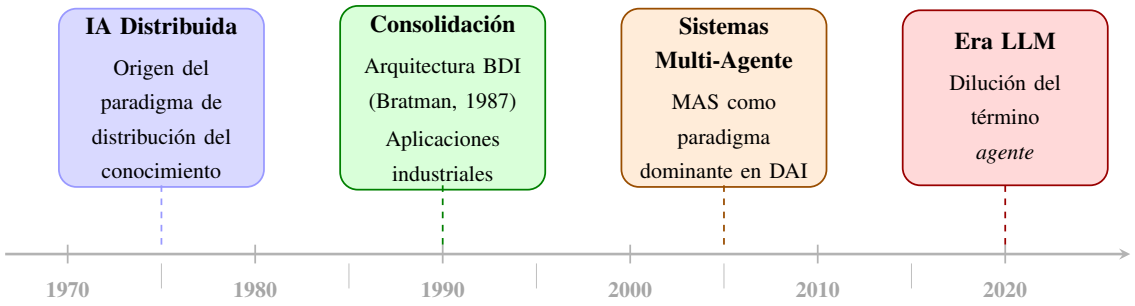
2.1.3. Contexto histórico y evolución

Este concepto de agente inteligente surge como derivado de la **Inteligencia Artificial Distribuida**. La IA distribuida, cuyo origen se remonta a los años 70/80, aparece en respuesta a la falta de socialidad de la ciencia cognitiva. Este nuevo paradigma de distribución del conocimiento trata de romper lo establecido hasta el momento y considerar el entorno como un escenario donde distintos elementos conviven y se relacionan [16].

Ya en la década de los 90, el «agente inteligente» empieza a consolidarse. Se presentan arquitecturas como la **BDI** presentada por Bratman [10] y discutida anteriormente, y empiezan a aplicarse los agentes a soluciones reales, como la implementación de sistemas autónomos en líneas de producción de bobinas de acero, o la gestión del tráfico del tren bala en Japón [17].

Durante los 2000, los sistemas Multi-Agente (o **MAS**) se establecen como el principal paradigma dentro de la Inteligencia artificial Distribuida, absorbiendo progresivamente la terminología y los objetivos de investigación que anteriormente se agrupaban bajo la denominación genérica de DAI [18].

En la actualidad, la llegada de los LLM (Large Language Models) ha supuesto una revolución en el ámbito de la **Inteligencia Artificial**, y el campo de los «Agentes inteligentes» también se ha visto afectado. Un estudio realizado por Botti [19], expone cómo estos nuevos modelos de lenguaje han expandido el concepto de *agente* al mundo y cómo eso ha generado una malinterpretación del término que se lleva discutiendo en la literatura todos estos años, comparando las distintas diferencias que existen entre el término clásico y la moda «Agéntica». En el presente trabajo, el término *agente* se emplea exclusivamente en su acepción clásica, conforme a las definiciones de Maes [3] y Jennings y Wooldridge [4] expuestas al inicio de esta sección.



Fuente: elaboración propia a partir de [10], [16]-[18], [20]

Fig. 2.2. Evolución histórica del paradigma de agentes inteligentes

2.1.4. Comunicación

Como ya se ha mencionado, uno de los conceptos clave de los agentes es el de sociabilidad, concepto que se presenta como habilitador necesario para la cooperación interagente. Es mandatorio establecer unos criterios para la correcta comunicación y entendimiento entre interlocutores. En respuesta a esto, a lo largo de la existencia de los agentes se han ido desarrollando unos estándares de comunicación para el correcto comportamiento de las comunicaciones.

El primero surge en 1993, denominado **KQML** (*Knowledge Query and Manipulation Language*) y desarrollado en el marco del programa *Knowledge Sharing Effort* de DARPA a principios de la década de 1990 [21]. KQML definía un formato de mensaje y un protocolo para el intercambio de conocimiento entre agentes, organizando cada mensaje en tres capas: contenido, comunicación y mensaje. Pese a su amplia adopción en la investigación inicial sobre sistemas multiagente, KQML presentaba limitaciones relevantes: la existencia de múltiples implementaciones incompatibles entre sí, y la ausencia de una semántica formal para sus performativos, cuyo significado se describía de forma informal [21].

En respuesta a estas limitaciones, en 1996 se fundó la *Foundation for Intelligent Physical Agents* (**FIPA**), una organización dedicada a la creación de estándares de interoperabilidad para sistemas basados en agentes. FIPA publicó entre 1997 y 2002 un conjunto de especificaciones que incluyen un lenguaje de comunicación propio (**FIPA-ACL**) [20], una biblioteca de actos comunicativos con semántica formal basada en lógica modal BDI [22], y un conjunto de protocolos de interacción que regulan la estructura de las conversaciones entre agentes como FIPA-Query y FIPA-Request. Estas especificaciones abordaron las principales debilidades de KQML, proporcionando una semántica formal, un conjunto estandarizado de performativos y protocolos de interacción predefinidos.

En 2005, FIPA fue aceptada como comité de estándares del *IEEE Computer Society*, bajo cuyo auspicio se mantienen actualmente las especificaciones. Si bien estas no constituyen estándares IEEE numerados en sentido formal, son consideradas el estándar de facto para la comunicación entre agentes en sistemas multiagente. El estándar FIPA es el elegido para el desarrollo de las distintas interlocuciones entre los agentes.

2.1.5. Plataformas de Desarrollo

El auge de los agentes supuso la creación de nuevos lenguajes y plataformas que permitieran la explotación de este nuevo paradigma. Múltiples soluciones han sido desarrolladas para satisfacer estas necesidades. Mayoritariamente surgieron entre finales de los 90 y principios de los 2000, cuando MAS se establece como estándar dentro de la DAI. Entre ellas se destacan JADE[23], NetLogo[24], MASON[25], Jason[26] y GAMA[27]. En la tabla 2.1, se muestra una comparativa de estas plataformas.

TABLA 2.1. COMPARATIVA DE PLATAFORMAS DE DESARROLLO DE SISTEMAS MULTIAGENTE

Característica	**JADE**	**NetLogo**	**MASON**	**Jason**	**GAMA**
Año	1999	1999	2005	2007	2007
Tipo	Middleware	ABM	ABM	BDI	ABM
Lenguaje	Java	NetLogo	Java	AgentSpeak	GAML
FIPA	Sí	No	No	No	Sí
GIS	No	Limitado	No	No	Sí
Modo batch	No	Sí	Sí	No	Sí
Escalabilidad	Media	Baja	Alta	Baja	Alta
Curva de aprendizaje	Media	Baja	Alta	Alta	Baja
Visualización	Limitada	Sí	Sí	No	Sí
Código abierto	Sí	Sí	Sí	Sí	Sí

Fuente: elaboración propia a partir de [23]-[27].

Como elección se ha escogido GAMA[27], una plataforma de código abierto, con lenguaje propio y construida sobre Java. Se escoge esta plataforma por tres motivos principales, la inclusión de FIPA[20] como estándar de comunicaciones, la integración con mapas geoespaciales y la facilidad de escalado. El incluir ya un estándar para la comunicación facilita su implementación dentro de la solución final, y debido a la naturaleza de los datos del problema, la integración de mapas GIS (Geographic information system) facilita la lectura de los datos de las rutas de los autobuses. Por último, el escalado está facilitado por el modo batch, que permite múltiples ejecuciones paralelas y un despliegue del código por línea de comandos. Estos motivos hacen que GAMA[27] se presente como plataforma idónea para este problema.

2.1.6. Viabilidad de la solución utilizando Agentes Inteligentes

En el contexto del problema a resolver tratado a lo largo de este documento, resulta necesario validar que el dominio existente en el que se encuentra sea el adecuado basándose en las características formales discutidas a lo largo de este apartado. Concretamente,

una de las principales características del problema se basa en la variación de oferta y demanda de pasajeros a lo largo de un conjunto de paradas durante un día concreto. Este entorno se presenta altamente **dinámico** y **complejo**, ya que existen multitud de factores que aleatorizan y varían el rango de soluciones, como la demanda variable dependiente de los cambios de hora. Por otra parte, el conocimiento relevante para el problema se encuentra **distribuido** entre múltiples puntos del sistema: la información sobre la demanda de pasajeros varía según la ubicación geográfica y la franja horaria, los tiempos de viaje dependen de tramos específicos del recorrido, y la disponibilidad operativa fluctúa de forma independiente en cada vehículo.

La verificación de que los agentes implementados satisfacen las propiedades discutidas —autonomía, reactividad, sociabilidad y proactividad— se aborda en el capítulo de diseño.

Es preciso concluir, por tanto,basándose en la literatura en el ámbito relativo al dominio, que una solución basada en agentes inteligentes resulta metodológicamente válida para el problema, satisfaciendo las condiciones discutidas con anterioridad.

2.2. Simuladores de Transporte

La simulación aborda un problema fundamental dentro de cualquier ámbito, ser capaz de recrear un escenario concreto con el fin bien de extraer o detectar posibles anomalías de una forma temprana, o de analizar resultados clave sobre un conjunto determinado. En el contexto del transporte urbano, validar las capacidades de absorción de la congestión en horas puntas resulta clave, al presentarse este como uno de los principales problemas para las entidades gestoras del transporte [28]. Esta sección cubre la evolución y las distintas técnicas existentes en la literatura usadas para realizar estos experimentos, junto con un análisis de distintas soluciones relativas al problema concreto que aborda este documento.

2.2.1. Técnicas de simulación

Las aproximaciones a la simulación del transporte pueden agruparse según su paradigma de modelado y su mecanismo de resolución. A continuación se presentan las principales familias de técnicas identificadas en la literatura, junto con sus aportaciones y limitaciones en el ámbito del transporte público.

1. **Técnicas matemáticas analíticas**

   Basadas en la resolución algebraica de problemas formalizados mediante ecuaciones construidas a partir de relaciones entre variables. En el ámbito del transporte, Newell y Potts [29] implementa un sistema matemático para análisis de estabilidad de rutas basado en ecuaciones diferenciales. Otros paradigmas, como puede ser la *teoría de colas*, o técnicas de *programación lineal* se presentan dentro de

los escenarios de transporte. Ejemplos como Wang et al. [30] o Wang et al. [31] implementan sistemas basados en teoría de colas dentro del caso de aplicación de modelado de rutas de autobús en China, mientras que Liu et al. [32] aplica técnicas de programación lineal para la optimización de transferencias dentro del transporte. Estos métodos de resolución se presentan adecuados en entornos claramente deterministas, donde la formalización matemática del problema puede realizarse bajo supuestos simples.

2. **Modelos microscópicos**

   Estas técnicas modelan a escala de individuo una serie de exhaustivas reglas sobre su comportamiento, resultando en un modelo muy complejo, capaz de extraer resultados muy realistas, con la contrapartida de un elevado coste computacional. Relativo a los casos de aplicación concretos, Li et al. [33] utiliza este tipo de modelos para analizar infraestructura de señales o de velocidad de tránsito para evaluar sus capacidades previa construcción, mientras que Zannat et al. [34] simula decisiones individuales de viajeros para predecir su demanda en la ciudad de Dhaka.

3. **Simulaciones de eventos discretos**

   Este tipo de simulaciones recrean y modelan aquellos momentos concretos de cambios de estado dentro de la simulación, ignorando el transcurso continuo del tiempo entre eventos relevantes. Dicha característica permite acelerar las simulaciones, pero puede perder precisión en eventos no estrictamente deterministas. En relación con su uso en las simulaciones de transporte, Tirachini et al. [35] o Arias Nava, Moncayo-Martínez et al. [36] utilizan eventos discretos para evaluar la demanda y su impacto en tiempos de espera.

4. **Algoritmos evolutivos y metaheurísticas**

   Este tipo de técnicas basadas en paradigmas de Inteligencia Artificial de inspiración biológica, se centran en la realización de procesos iterativos que aplican operadores de selección, recombinación y perturbación de las soluciones inspirados en fenómenos naturales, utilizando funciones de coste (heurísticas) para converger hacia soluciones cercanas al óptimo. Resultan muy útiles en aquellos problemas donde la combinatoria de posibles resultados válidos tiende a ser computacionalmente compleja. Casos como Owais y Osman [37] o Jha et al. [38] estudian el diseño de redes de tránsito de transporte basados en estas técnicas.

5. **Sistemas multi-agente**

   Basados en los conceptos de *agente inteligente* ya discutidos y expuestos en la sección 2.1, resultan útiles en escenarios dinámicos y complejos, que requieran de interacción o colaboración entre individuos. En la literatura se pueden encontrar trabajos como Saval et al. [39], que utiliza un sistema multi-agente para estudio de rendimiento de rutas, o Shaharuddin y Misro [40], usado para comparar los resultados derivados de simular dos escenarios de tráfico.

6. **Aprendizaje profundo por refuerzo**

   Conjunto de técnicas basadas también en paradigmas de la Inteligencia Artificial. Consta de la mezcla del aprendizaje por refuerzo, sistema de aprendizaje iterativo que aprende en base a una política de actuación, recibiendo recompensas que guían la optimización en el largo plazo, con técnicas de «deep learning» (aprendizaje profundo), consistente en redes neuronales que permiten aprender estrategias de control adaptativas en tiempo real. Se presenta útil en entornos cambiantes. En casos de transporte, Bajada et al. [41] o Tang et al. [42] implementan esta mezcla con el objetivo de mejorar la toma de decisiones de los autobuses en tiempo real.

Estas técnicas se presentan como opciones realistas para realizar simulaciones dentro del transporte urbano. No obstante, cada familia presenta características que condicionan su adecuación al problema concreto de este trabajo: **la simulación operacional de una línea de autobús urbano**, parametrizada con datos reales, en un entorno dinámico donde múltiples entidades autónomas (autobuses, paradas, pasajeros) interactúan de forma concurrente.

Las técnicas matemáticas analíticas requieren una formalización algebraica del problema bajo supuestos deterministas, lo que las hace inadecuadas para capturar la variabilidad inherente a la demanda de pasajeros y a los tiempos de recorrido. Los modelos microscópicos, si bien operan a escala de individuo, están orientados predominantemente a la simulación de tráfico vehicular (modelos de seguimiento de vehículos, cambio de carril), y su elevado coste computacional no se justifica para la operación del servicio de transporte público. Las simulaciones de eventos discretos permiten modelar cambios de estado puntuales con eficiencia temporal, pero imponen una estructura de eventos determinista que limita la autonomía de las entidades simuladas y dificulta la representación de comportamientos emergentes derivados de la interacción. Los algoritmos evolutivos y las metaheurísticas constituyen técnicas de *optimización*, no de *simulación*: su objetivo es encontrar configuraciones cercanas al óptimo, no recrear la operación real de un sistema para extraer indicadores de rendimiento. Finalmente, el aprendizaje profundo por refuerzo, aunque capaz de adaptarse a entornos cambiantes, requiere el diseño de funciones de recompensa y una infraestructura de entrenamiento que excede el alcance de este trabajo, y su orientación es la optimización de decisiones futuras, no la reproducción de escenarios operacionales existentes.

Frente a estas limitaciones, los sistemas multi-agente se presentan como la técnica más adecuada para el problema planteado. Su capacidad de modelar entidades autónomas que operan en un entorno altamente cambiante y dinámico se alinean con el dominio de aplicación del problema.

2.2.2. Sistemas Multi-Agente como simuladores

En esta sección se expande el estudio sobre los distintos trabajos realizados en el ámbito de las simulaciones de transporte basadas en el paradigma de los *agentes inteligentes* y los *sistemas multi-agente*.

Pese a la elección como sistema para la solución de la arquitectura multi-agente, resulta necesario posicionar esta dentro de las simulaciones de transporte. Los modelos microscópicos resultan los más empleados para la resolución de problemas, mediante herramientas como SUMO [43] o VISSIM [44], que emergen como referentes [28]. La diferencia principal radica en el contexto relativo dentro del transporte que se busca. Como se ha especificado anteriormente, la simulación microscópica centra su ámbito de investigación en el modelado a nivel vehicular, no a nivel de análisis operacional de transporte. A continuación se revisan los principales trabajos que aplican sistemas multi-agente a la simulación de transporte, con especial atención a aquellos orientados a la operación de líneas de autobús.

Primeramente, a nivel general, Divasson-J. et al. [45] expone una revisión de las distintas aportaciones basadas en *agentes*. Documenta un uso creciente de estas herramientas desde 2015, alineandose con la adopción de los países de objetivos climáticos o de la *Agenda 2030* [8]. En relación a la caracterización del problema, la simulación de análisis de demanda supone un **5,19 %** de las publicaciones, resultando mayoritario con un *62,34 %* el estudio sobre estado de tráfico. Se expone por otra parte una comparativa entre las características de los datos utilizados. De forma relevante a este trabajo, que utiliza datos reales de operación de ruta de autobús, también resulta minoría sobre la literatura estudiada, destacando en este caso el uso de *Datos abiertos* (33,12 %) o de *datos sensoriales* (21,43 %) [45].

Respecto a estudios relevantes para este trabajo, Morri et al. [46] implementa un sistema multi-agente junto a KPIs sobre la ciudad de Abu Dhabi. A diferencia de este proyecto, el uso de los indicadores de rendimiento se realiza de forma dinámica, usando estos como parámetro clave para la toma de decisiones de los agentes mediante técnicas de programación lineal [46], de forma contrapuesta a lo usado en el presente trabajo, que busca usar KPIs como medida evaluadora del rendimiento una vez completada la simulación.

Chambers et al. [47] por otro lado utiliza agentes para generar redes de tráfico en Suiza. Se basa en grafos de conocimiento y ontologías para generar estas redes. No obstante, no guarda relación con este trabajo debido a su propósito, pero permite trazar otras líneas de investigación sobre rutas de autobuses y el uso de sistemas *multi-agente* existente en la literatura.

Más cercano a la aplicación de este trabajo se ubica Fanfani et al. [48], que implementa

[8] «La Asamblea General adopta la Agenda 2030 para el Desarrollo Sostenible», 25 de septiembre de 2015. Disponible en: https://www.un.org/sustainabledevelopment/es/2015/09/la-asamblea-general-adopta-la-agenda-2030-para-el-desarrollo-sostenible/ (accedido: 3 de junio de 2026)

un sistema basado en *agentes inteligentes* para simulación y análisis de líneas de autobús mediante KPIs. Diferencias relevantes radican en el origen de los datos, debido a que este usa datos sintéticos basados en GTFS (de sus siglas en inglés: General Transit Feed Specification) y no en datos reales de operación como se aplica en el presente documento. Esto deriva no solo en posibles pérdidas de información sobre carga y descarga, sino en falta de precisión en los tiempos, puesto que se usan las salidas explícitas presentes en la especificación en lugar de tiempos de salida dinámicos basados en datos reales.

Una vez estudiada la literatura subyacente acerca de los sistemas *multi-agente* y las simulaciones en el ámbito del transporte, puede realizarse el posicionamiento de este dentro del estado del arte. La principal aportación existente de este trabajo resulta de la aplicación del sistema de agentes inteligentes utilizando datos **reales** sobre la operación de autobuses, a diferencia de Fanfani et al. [48]. Los resultados de esta se plasman mediante Key Performance Indicators y se visualizan con el fin de facilitar su visualización.

Para el correcto funcionamiento de la simulación, resulta necesario remarcar dos cuestiones relevantes acerca de esta. La primera consta de la especificación de uso de distribuciones contínuas conocidas para el tratamiento de los distintos datos usados como entrada del simulador. Estas distintas distribuciones se expanden en la Sección 2.2.4. La otra, expuesta en la siguiente sección, trata del motor utilizado para la realización de las simulaciones, correspondiente con el **algoritmo de Monte Carlo**.

2.2.3. Simulaciones de Monte Carlo

Las simulaciones o experimentos de Monte Carlo datan de 1949, donde en Los Álamos durante el *Proyecto Manhattan*, Metropolis y Ulam [49] formalizaron un método para el problema de la difusión de neutrones. Este sistema permite predecir o estimar los resultados de un proceso aleatorio. Fue bautizado como *Monte Carlo* debido a la comparativa entre la aleatoriedad inherente que predice el método y los populares juegos de azar presentes en el conocido casino del distrito monegasco homónimo al experimento.

Formalmente, sea θ un parámetro de interés (KPI) dependiente de un conjunto de variables aleatorias $x_1, x_2, \ldots, x_k$ relativas a los parámetros estocásticos del sistema, donde cada x_i tiene asociada una función de densidad de probabilidad F_i, cada iteración j de Monte Carlo consta de, previa extracción de muestras independientes $x_1^{(j)}, x_2^{(j)}, \ldots, x_k^{(j)}$, el cómputo del valor resultante expresado por:

$$\theta^{(j)} = g(x_1^{(j)}, x_2^{(j)}, \ldots, x_k^{(j)}) \tag{2.1}$$

donde g representa el modelo simulado. Del cómputo de N se obtiene:

$$\hat{\theta_N} = \frac{1}{N} \sum_{j=1}^{N} \theta^{(j)} \tag{2.2}$$

Donde $\hat{\theta_N}$ especifica cada uno de los parámetros usados como indicadores de rendimiento, las distribuciones F_i se obtienen de un estudio derivado de los datos de operación,

y g hace referencia al modelo realizado en GAMA.

Este método, usado como motor estocástico de la simulación,requiere de un parámetro N relativo al número de repeticiones a realizar. Para el caso concreto de aplicación, la elección de este valor se justifica en dos ángulos. El primero, presente en la figura 2.3 muestra la evolución del valor $\hat{\theta}_i$ desde $i = 1$ hasta $i = N$. Se observa cómo el inicio presenta mucha variabilidad, estabilizándose hacia las 400-500 iteraciones.

El segundo ángulo, usado para la mejora de este valor, deriva de la ley de los grandes números [50]. Esta, formalmente especifica:

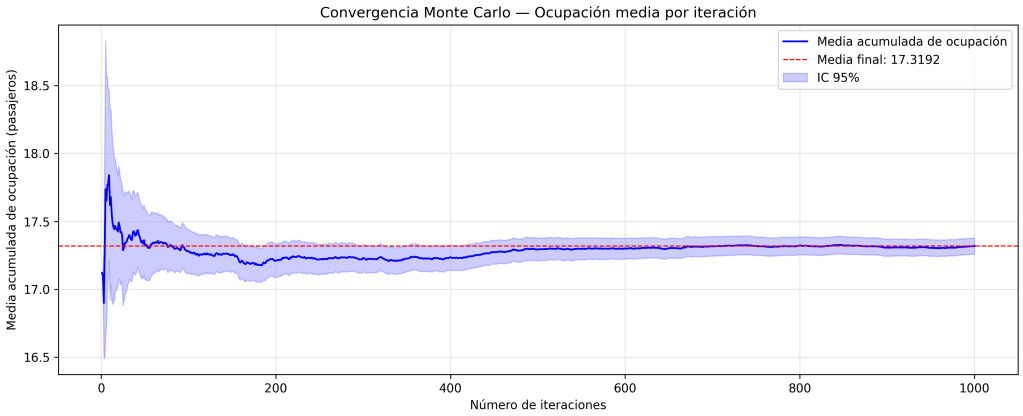
$$\hat{\theta_N} \xrightarrow{\text{c.s.}} \mathbb{E}[\theta] \quad \text{cuando } N \to \infty \tag{2.3}$$

y su error estándar puede formalizarse como:

$$SE(\hat{\theta_N}) = \frac{\sigma_\theta}{\sqrt{N}} \tag{2.4}$$

De esta forma, al aumentar el número N, se produce un decrecimiento no lineal del error estándar sobre los distintos parámetros de interés.

Juntando ambas ideas, se puede reducir en un **29,3 %** el error estándar derivado al elevar de 500 a 1000 el valor de N usado. Aumentar dicho parámetro por encima de esta cota resultaen mejoría del descenso de este error, pero incurre en coste computacional que no es justificable para el valor de mejora que se obtiene.



Fuente: elaboración propia.

Fig. 2.3. Evolución de convergencia relativa a parámetro de Monte Carlo

2.2.4. Análisis estadístico de datos

En esta sección se exponen y discuten los distintos métodos estadísticos utilizados para la validación de las distribuciones de los datos estudiados. Para ello, se divide el contenido en las secciones «Test de Hipótesis» y «Estudio de valores extremos».

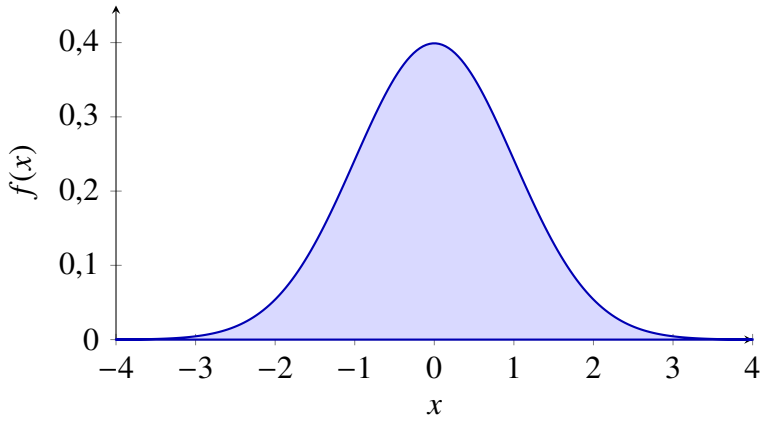
Test de Hipótesis

Los test de hipótesis suponen el principal método de validación de distribuciones empíricas. Se han usado diferentes distribuciones conocidas a lo largo de este trabajo, como son la distribución **Normal** o **Gaussiana**, la distribución **Binomial Negativa** y la distribución **Geométrica**. Esta subsección expone cómo son estas distribuciones y cuáles son los distintos test existentes para estas, discutiendo sobre la viabilidad de sus aplicaciones.

La viabilidad de sus aplicaciones, a parte de las características estadísticas de su validación o no como hipótesis deben cumplimentar el estudio relativo de la literatura que especifica un nivel de calibración superior al **85 %** para poder considerarse adecuado dentro del estudio de la simulación de transporte [51]. Este valor será utilizado para validar el modelo como distribuciones de los datos.

Distribución Normal o Gaussiana

Posiblemente la más conocida, es una distribución característica por su simetría y su forma de *campana*. En la figura 2.4 se muestra la típica forma que deriva de esta distribución.



Fuente: elaboración propia.

Fig. 2.4. Representación de la distribución normal o de Gauss ($\mu = 0$, $\sigma = 1$)

La función de densidad de la distribución normal viene dada por:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \tag{2.5}$$

Donde μ resulta la media aritmética del conjunto de datos y σ la desviación estandar. El origen de esta fórmula deriva de los estudios de Moivre [52], Laplace [53] y Gauss [54].

Existen muchos test que permiten evaluar la normalidad de una muestra. En la literatura destacan el *Shapiro-Wilk*, *Kolmogorov-Smirnov*, *D'Agostino-Pearson* y *Jarque-Bera*. Estudios comparativos como el de Yap y Sim [55], que evalúa la potencia de ocho tests mediante simulación de Monte Carlo, concluyen que ninguno de ellos es uniformemente

superior para todos los tipos de distribución alternativa, y que la elección debe atender al tamaño muestral y a las características de los datos. Debido a la naturaleza inicial de los datos estudiados, presentando tamaños muestrales estimados de unas 20 muestras, se opta por un enfoque de Test de hipótesis basado en la **skewness** (*asimetría*) y la **kurtosis** (*curtosis*). Kim [56] especifica que este test en cuestión permite ser utilizado con rigor estadístico para estudio de normalidad en muestras pequeñas, por lo que se optó por su implementación.

Skewness y kurtosis son coeficientes que se obtienen calculando y estandarizando los momentos centrales de una distribución.

Estos coeficientes, (*skewness*, γ_1) y (*kurtosis*,γ_2) caracterizan, respectivamente, la simetría y el peso de las colas de una distribución respecto a la distribución normal. Un valor de $\gamma_1 = 0$ indica simetría perfecta; valores positivos señalan una cola derecha más pesada y valores negativos una cola izquierda más pesada. En cuanto a la kurtosis en exceso (γ_2), un valor de cero corresponde a una distribución *mesocúrtica* (similar a la normal), valores positivos indican una distribución *leptocúrtica* (colas más pesadas) y valores negativos una distribución *platicúrtica* (colas más ligeras).

El test de normalidad empleado evalúa si los valores observados de γ_1 y γ_2 son estadísticamente compatibles con los esperados bajo una distribución normal, mediante la estandarización de ambos coeficientes en puntuaciones Z y su comparación con el nivel de significación $\alpha = 0{,}05$ [56].

La diferencia existente entre el test implementado y el «D'Agostino-Pearson», que también utiliza coeficientes basados en *skewness* y *kurtosis*, radica en la combinación de ambos valores para la toma de la decisión de rechazo en el caso de D'Agostino-Pearson [57], mientras que en el propuesto por Kim [56], se consideran ambos coeficientes de manera independiente. De esta forma, no solo se obtiene información acerca de si la distribución testada se comporta como una normal, sino de cuáles son las causas concretas que concretan el rechazo.

Distribución Binomial Negativa y Distribución Geométrica

Encapsuladas en un apartado debido a la particularidad de la distribución *geométrica*, que resulta ser un caso de aplicación concreto de la distribución *Binomial Negativa*, y debido al uso conjunto que se hace de estas dos distribuciones en el caso concreto de aplicación.

La distribución binomial Negativa, representada en la figura 2.5, consiste en un tipo de distribución discreta basada en una prominente cola derecha (skewness positivo). Esta característica se encuentra presente también en la distribución *geométrica* (véase la figura 2.6).

La distribución *binomial negativa* normalmente se emplea para modelar el número de intentos necesarios para conseguir un determinado número de aciertos bajo condiciones probabilísticas. La *geométrica*, como caso particular, modela el número de intentos hasta

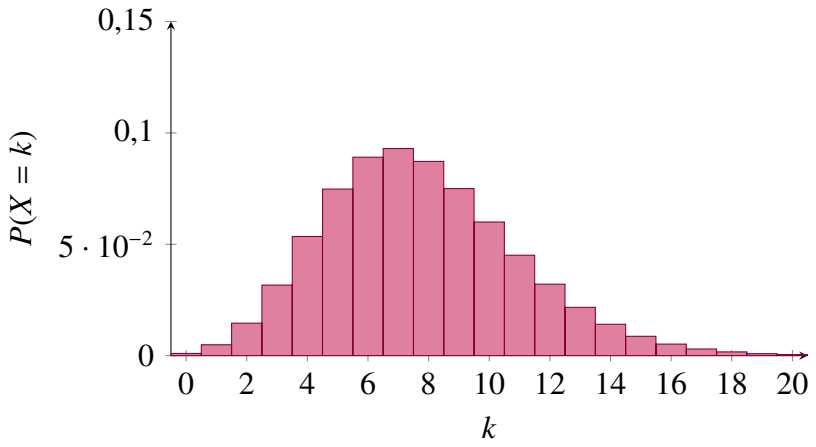
conseguir exactamente **un acierto**. Ambas distribuciones toman un parámetro referente a la *probabilidad de éxito* y otro referente al *Número de aciertos*.

Matemáticamente, la función de masa de probabilidad de la distribución binomial negativa viene dada por:

$$P(X = k) = \binom{k + r - 1}{k}(1 - p)^k p^r, \quad k = 0, 1, 2, \ldots \tag{2.6}$$

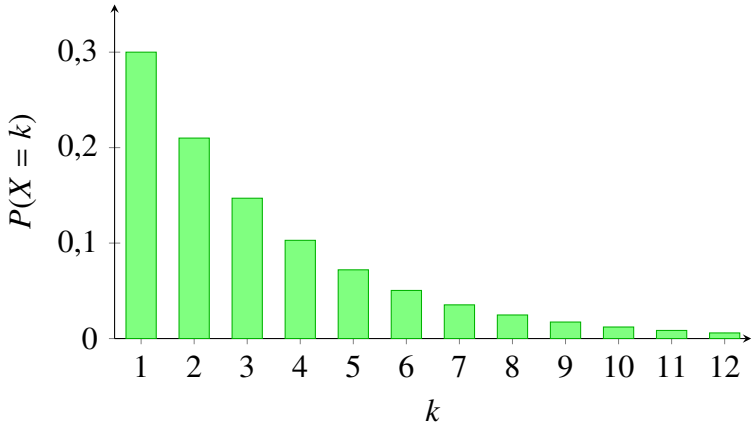
donde r es el número de éxitos y p la probabilidad de éxito. La distribución geométrica constituye el caso particular $r = 1$:

$$P(X = k) = (1 - p)^{k-1} p, \quad k = 1, 2, 3, \ldots \tag{2.7}$$



Fuente: elaboración propia.

Fig. 2.5. Representación de la distribución binomial negativa ($r = 5$, $p = 0{,}4$)



Fuente: elaboración propia.

Fig. 2.6. Representación de la distribución geométrica ($p = 0{,}3$)

Dentro del caso de aplicación que concierne a este trabajo, estas distribuciones se han utilizado para modelar los distintos valores de subida y bajada de pasajeros en una parada

concreta. Bajo este tipo de escenarios, una distribución de *Poisson* resulta más factible en un principio, dado que esta modela el número de eventos que ocurren en un intervalo de tiempo concreto bajo la premisa de su independencia [58]. No obstante, esta distribución captura peor que la *binomial negativa* aquellos casos donde la varianza es mayor que la media [58], coincidente con la casuística de los datos de operación de la EMT. Por este motivo concreto, aunque el contexto de qué implican las distribuciones *binomial negativa* y *geométrica* no se corresponda con su definición formal, se aplican estas al capturar mejor aquellos casos donde se presenta una sobredispersión derecha considerable.

Los test de hipótesis para el estudio de estas distribuciones se basan en un enfoque clásico de **bondad de ajuste** mediante el estadístico χ^2 de Pearson [59]. Para ello, se estiman previamente los parámetros de cada distribución a partir de la muestra observada, calculando posteriormente las frecuencias esperadas y comparándolas con las frecuencias empíricas obtenidas. Siguiendo las recomendaciones de Cochran [60], aquellas categorías con frecuencias esperadas reducidas se agrupan para mantener la validez estadística del contraste. En el caso de la distribución binomial negativa, la estimación de parámetros se realiza mediante el método de los momentos, mientras que para la distribución geométrica se emplea el estimador de máxima verosimilitud sobre el parámetro de éxito.

Estudio de valores extremos

En relación al estudio de los valores extremos (comúnmente conocidos como *outliers*), se pueden distinguir dos casos concretos en los que se ha realizado este análisis.

Estudio de Normalidad

En el estudio de la normalidad de los datos, se busca validar mediante Test de hipótesis si los datos a estudiar se asemejan a una distribución gaussiana, asunto ya discutido y explicado. En caso de que no se valide el test, entra en juego el análisis de los posibles valores atípicos. Dentro del análisis de normalidad de los datos, existen en la literatura distintos tests. El «NIST» (National Institute of Standards and Technology) [9] define tres preguntas clave para la elección del mejor estimador. Estas preguntas son: ¿Qué distribución siguen los datos?, ¿Test diseñado para encontrar uno o varios *outliers*? y, si está diseñado para más de uno, ¿Es necesario especificar cuántos existen o solo una barrera superior?[61].

Según la respuesta a estas preguntas se puede reducir el número de modelos que sirvan para el caso concreto. Dentro del problema en cuestión, se busca encontrar qué *outliers* pueden existir en distribuciones *Normales*. En este caso, se definen tres posibilidades, el «Test de Grubbs», el «Test de Tietjen-Moore» y el «Generalized Extreme Studentized Deviate Test» (o ESD). ESD se presenta como el único de los tres que no necesita la especificación concreta de cuántos outliers existen en un conjunto de datos (Grubbs establece **un único outlier**, mientras que Tiejten-Moore necesita el **número exacto**). Al

[9] https://www.nist.gov/ (accedido: 13 de mayo de 2026).

buscar la utilización de test detectores de valores anómalos en una fase de estudio de los datos, los dos primeros test se presentan incompatibles. El ESD es un test propuesto por Rosner en 1983 [62], derivado de la generalización del Test de Grubbs para detección de múltiples outliers, y que opera sobre una distribución **aproximadamente normal**. Recibe como único parámetro r, un límite superior utilizado para el planteamiento de la hipótesis alternativa. Las hipótesis H_0 y H_a son:

$$H_0 : \text{No hay outliers}$$
$$H_a : \text{Hay hasta } r \text{ outliers}$$

Posteriormente, se sigue un proceso iterativo, en el cual se computa la siguiente fórmula para cada iteración i:

$$R_i = \frac{\text{máx}_i \, |x_i - \bar{x}|}{s} \tag{2.8}$$

Donde $\bar{x}$ denota la media y s es la desviación estándar muestral, que difiere de m_2(desviación estándar de la población) en que en su cálculo se multiplica por $\frac{1}{n-1}$ en vez de $\frac{1}{n}$ En cada iteración se encuentra el valor que maximiza esa R_i, y se almacena. En la siguiente iteración $i + 1$ se recalcula esa R_{i+1} sin tener en cuenta el valor anterior

Esto se repite hasta que se han computado los r datos de la H_a

Luego, con un nivel definido de significancia α, para cada R_i con $i \in 1, 2, \ldots, i$ se calcula un valor λ_i

$$\lambda_i = \frac{(n-i)\, t_{p,n-i-1}}{\sqrt{\left(n-i-1+t^2_{p,n-i-1}\right)(n-i+1)}} \tag{2.9}$$

Donde $t_{p,v}$ se corresponde con el cuantil p de la distribución t con v grados de libertad. En estas fórmulas, v se corresponde con $n - i - 1$ y p con

$$p = 1 - \frac{\alpha}{2\,(n-i+1)} \tag{2.10}$$

De todo esto obtenemos que el número de outliers es determinado según el máximo valor i que cumpla que $R_i > \lambda_i$ [61], [62].

Una vez formalizado el algoritmo comprobador de *outliers*, resulta necesario discutir el correcto uso o aplicación de este a la hora de verificar posibles anomalías. La definición del test, asume que se hace sobre una distribución **aproximadamente normal**. En el caso de aplicación del problema, en una fase de validación, se aplica este test para detectar posibles anomalías sobre distribuciones que no han superado el test de normalidad. Esto puede parecer contradictorio con la definición formal, pero el NIST reconoce esta aplicación bajo un supuesto concreto. El instituto reconoce la posible paradoja del «huevo y la gallina». Es decir, los datos detectados como anómalos sobre una distribución no normal son una muestra de que la distribución de ese conjunto de datos efectivamente no se puede considerar gaussiana, o esos *outliers* detectados se deben a observaciones anómalas y no a una distribución subyacente genuinamente no-normal. El NIST asume esta paradoja y especifica, que es considerable aplicar este test si de forma gráfica, mediante plots, existe una suposición razonable de normalidad.[61]

En este aspecto, en etapas iniciales con pocas muestras de datos, se ha realizado este test bajo previo análisis gráfico de los datos, en aquellos escenarios donde la posible normalidad representaba una hipótesis razonable. En casos expandidos con múltiples validaciones, se ha utilizado de una forma acotada y considerada. Bajo tamaños muestrales que rondan las 400 muestras, se ha implementado este test bajo especificación de una cota no superior al **1 %** del total de los datos, lo que representativamente supone una medida de hasta 6 outliers posibles en la distribución. Este valor permite representar un margen lo suficientemente pequeño como para poder ser utilizado como límite superior en la hipótesis alternativa del test sin dañar el comportamiento genuino de los datos [63].

Selección de distribuciones

En el caso de un proceso de selección de distribuciones, es decir, ver qué tipo de distribución se asemeja más al conjunto de datos a estudiar, es estadísticamente incorrecto aplicar el ESD, ya que este se encuentra diseñado para aplicarlo sobre conjuntos de datos «*aproximadamente normales*». Para el estudio de *outliers* sobre conjuntos de datos que pueden ser o pueden no ser normales, resulta más adecuado un test con un enfoque general sobre la consideración de una anomalía en los datos. En la literatura existen diversos test que permiten analizar posibles valores atípicos dentro de un conjunto de datos. Leys et al. [64] discute sobre preferencia de realizar otros enfoques distintos al clásico de considerar *outliers* a aquellos datos más allá de dos o tres veces la *desviación estandar*. Expone que la media y la mediana son valores sensibles a esos *outliers* y propone utilizar el **MAD** (Median Absolute Deviation) como un estimador más robusto, con la *mediana* como tendencia central.

En este trabajo, se utiliza el enfoque del **MAD** para el estudio de posibles valores anómalos en aquellos momentos donde se intenta evaluar cuál es la distribución que mejor se adapta a un conjunto de datos.

3. METODOLOGÍA

En este capítulo se explican de forma precisa y justificada los distintos métodos seguidos en este problema, así como la presentación de un esquema del desarrollo. Para ello, se expone primeramente la contextualización avanzada del problema en cuestión a resolver, seguido de la explicación de las distintas etapas que constituyen el trabajo. Posteriormente, se mencionan las distintas herramientas que se usan en este proyecto. De forma final se exponen las distintas métricas de rendimiento utilizadas para la fase de validación y de extracción de resultados.

3.1. Definición del problema

Este trabajo se realiza dentro de la Cátedra *Inteligencia Artificial para el Transporte y Movilidad*[10]. Esta establece un nexo colaborativo entre la EMT y la Universidad a través del grupo de investigación GIAA[11]. Como se explica de forma breve en la introducción, la Empresa Municipal de Transportes propone estudiar la viabilidad de la construcción de un sistema para analizar el rendimiento de rutas de autobuses. El principal motivo detrás de este planteamiento es la falta de un simulador propio para realizar esta tarea, que se suma a la existencia de una entidad superior a la EMT, el CRTM (Consorcio Regional de Transportes de Madrid) [12], que se encarga de validar diariamente las dotaciones propuestas por la compañía de autobuses. La «caja negra» que implica este paso para la validación supone un componente extra que justifica esta propuesta. La realización de este proyecto se ha enmarcado en un trabajo de investigación de una duración de ocho meses a lo largo de los cuales se ha ido desarrollando la solución planteada, bajo la supervisión bisemanal por parte de la EMT mediante reuniones telemáticas.

En una fase de desarrollo inicial, se propuso por parte de la EMT la evaluación de las cinco líneas *express* de la compañía, al ser líneas con un número de paradas bajo relativo al general de las rutas. Esta distinción permite acotar el análisis previo a la simulación, necesario para la validación de la viabilidad del simulador.

Una de las decisiones más relevantes para la comprensión del alcance de este trabajo es la de simular el comportamiento únicamente de los **días normales de operación**, excluyendo datos relativos a festividades, cambios de estación o eventos de gratuidad promovidos por la compañía. Los distintos motivos detrás de esta decisión se enuncian en la

[10] La UC3M y EMT Madrid presentan una nueva Cátedra en Inteligencia Artificial para el transporte y la movilidad https://www.uc3m.es/ss/Satellite/UC3MInstitucional/es/Detalle/Comunicacion_C/1371438766717/1371216001122/La_UC3M_y_EMT_Madrid_presentan_una_nueva_Catedra_en_Inteligencia_Artificial_para_el_transporte_y_l (accedido: 6 de mayo de 2026).

[11] (Grupo de Inteligencia Artificial Aplicada) https://giaa.uc3m.es/ (accedido: 6 de mayo de 2026).

[12] https://www.crtm.es/ (accedido: 6 de mayo de 2026)

sección 4.2 y posibles variaciones de este análisis se discuten en el capítulo 9.

Para la utilización de datos reales, la EMT puso a disposición una base de datos relacional con los datos de operación de las paradas de las líneas Express desde el 1 de julio de 2025, con actualizaciones diarias, permitiendo ir ampliando la base que compone el análisis a medida que se iba completando.

3.2. Estructura de trabajo

El proyecto se puede separar en cuatro partes características. A continuación, se expone cada una con —Nombre, Duración, Explicación de contenido—. En la figura 3.1 se puede ver, representado a modo de diagrama de *Gantt*, las distintas fases espaciadas en el tiempo.

- **Investigación y Planteamiento**: Duración [6 semanas]

  Supone la fase inicial del trabajo. Al no disponer de los datos, expandidos en el capítulo 4, y debido a la naturaleza investigadora del trabajo, en una primera etapa, se realizó un análisis del estado de la cuestión, expuesto en la sección 2, junto con un estudio de la plataforma GAMA [27], con el fin de realizar un acercamiento a los conceptos, estándares y herramientas que se usan a lo largo del desarrollo. Durante esta fase, a lo largo de las reuniones bisemanales, se acota el rango de aplicación del simulador, reduciéndose de las cinco líneas express inicialmente deseadas, a la línea E01, con el fin de no sobrecargar el análisis de la fase posterior.

- **Análisis y Parametrización de Datos**: Duración [12 semanas]

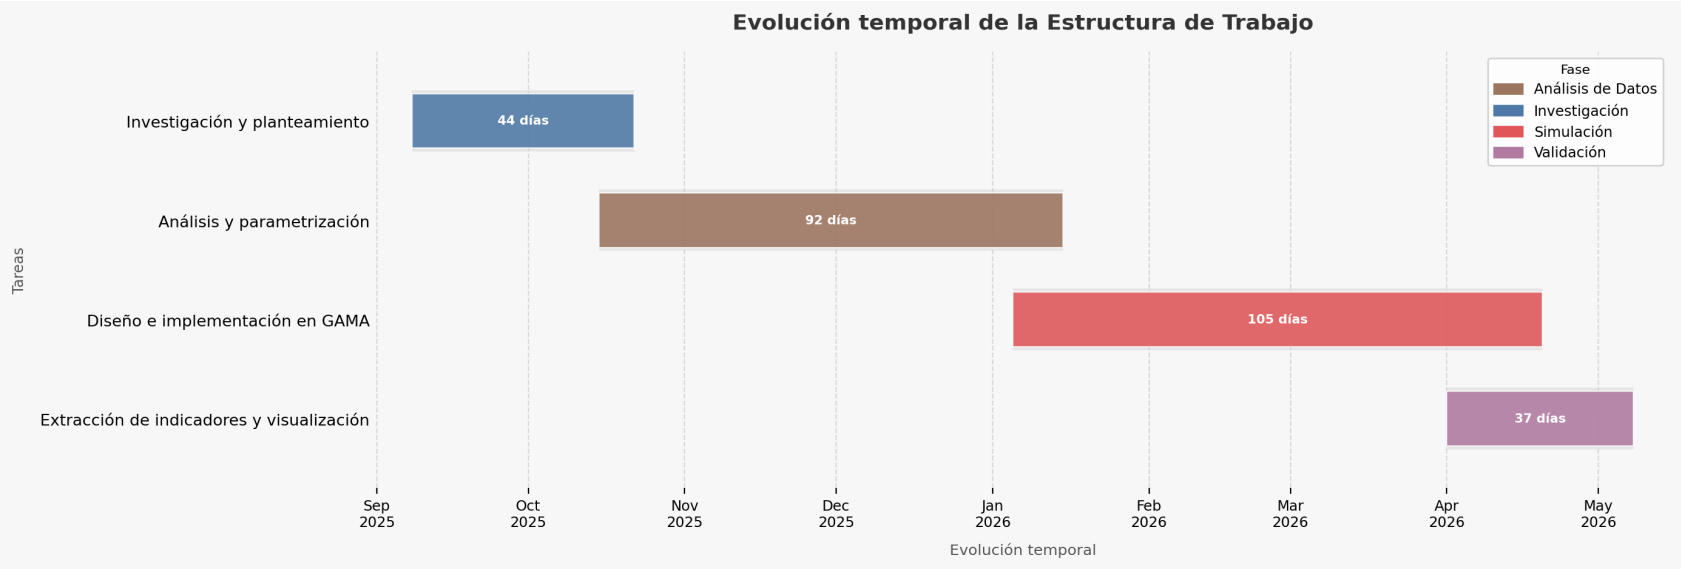
  En esta etapa se realiza un estudio exhaustivo sobre los datos facilitados, tanto los datos geoespaciales de la ruta, como los datos de operación de los autobuses. A lo largo de estas doce semanas, se procesa esta información para analizar la viabilidad de la solución planteada durante la fase uno, basándose en criterios estrictos de modelado de distribuciones para los distintos parámetros que sirven de entrada al simulador.

- **Diseño e Implementación en GAMA**: Duración [14 semanas]

  Una vez estudiada la viabilidad de usar los datos de operación de autobuses y preparados los parámetros de entrada al simulador, en esta etapa se construye la arquitectura del sistema multiagente y su desarrollo en el lenguaje propio de GAMA «GAML» [27]. A lo largo de esta fase, expandida posteriormente, se construyen dos modelos distintos: uno en el que los pasajeros se representan como agentes individuales con comportamiento propio, y otro en el que las subidas y bajadas se modelan de forma agregada por parada, priorizando el rendimiento computacional de la simulación.

- **Extracción de indicadores y visualización**: Duración [5 semanas]

  En esta última fase, se parte del simulador prácticamente completado, y se construye una herramienta de visualización y de lanzamiento en local de los distintos escenarios que plantee el usuario. Por otra parte, se completa el simulador con el feedback de formato de datos que requiere el extractor de KPIs.



Fuente: Elaboración propia.

Fig. 3.1. Diagrama de Gantt explicativo relativo a las distintas fases del desarrollo

3.3. Herramientas Utilizadas

En esta sección se exponen las distintas herramientas utilizadas para la construcción del sistema, junto a una breve explicación de su peso en ella.

- **GAMA**[13]: Usada en el desarrollo del sistema multi-agente, facilita la implementación del estándar de comunicaciones FIPA [20] y la inclusión de mapas geoespaciales.
- **Jupyter Notebook**[14]: Herramienta usada con kernel de *Python* para el análisis de los datos de operación de la línea a simular. Facilita la visualización de resultados, el análisis exploratorio de datos o la construcción de modelos estadísticos. Con su estructura de celdas «markdown» y sus celdas de código, mejora la lectura y la explicabilidad de los procesos que se realizan en cada documento «ipynb» (formato de cuadernos Jupyter).
- **QGIS**[15]: Necesaria para la conversión de GeoJSON (Formato basado en JSON con especificación concreta de parámetros para representación geográfica de los datos) a archivo ESRI shapefile (formato estándar de representación vectorial de datos geoespaciales). Usada para la carga en el simulador de los datos de la ruta y de la ubicación de las paradas.
- **Node.js**[16]: Framework de desarrollo web utilizado para el despliegue de la herramienta en *local*. Permite la creación de una arquitectura cliente/servidor que permita la conexión entre acciones o deseos del usuario en el navegador y su correspondiente cambio en la máquina anfitriona. Facilita la visualización de las simulaciones o el lanzamiento de nuevas.
- **Docker**[17]: Usado para la estandarización y aislamiento de procesos, facilitando el uso global del sistema. Utilizado para el despliegue de un contenedor encargado de la ejecución del programa completo, emulando un «gemelo digital» con las características del ordenador utilizado para el desarrollo. Gracias a esta herramienta, se permite ejecutar simulaciones en entornos sin la plataforma de desarrollo de agentes instalada.
- **Python**[18]: Lenguaje de programación usado para la extracción de métricas de rendimiento de las distintas simulaciones. Sus librerías diseñadas para análisis de datos sobre grandes volúmenes como puede ser el caso de *pandas* o generación de gráficas concretas con *matplotlib* permiten construir estas KPIs con mayor facilidad.

[13] https://gama-platform.org (accedido: 16 de mayo de 2026).
[14] https://jupyter.org (accedido: 9 de mayo de 2026).
[15] https://qgis.org (accedido: 9 de mayo de 2026).
[16] https://nodejs.org (accedido: 9 de mayo de 2026).
[17] https://www.docker.com (accedido: 9 de mayo de 2026).
[18] https://www.python.org (accedido: 9 de mayo de 2026).

Sobre las herramientas físicas utilizadas, se ha dispuesto de un portátil MSI Modern 15 C13M-273XES, modelo con 16 núcleos lógicos, 32GB RAM DDR4 y almacenamiento NVMe. Esta información, junto a detalles sobre presupuesto, se expanden en el capítulo 8, pero cabe ser destacada por su relación a las herramientas usadas y su interés en la interpretación a nivel de tiempo en la fase de **Diseño e implementación**, así como en la relativa a **Extracción de indicadores y visualización**.

Todo el desarrollo del trabajo se ha realizado sobre el sistema operativo Ubuntu 24.04 LTS, distribución de Linux basada en Debian. Esta elección de Sistema Operativo, sumado al conjunto de herramientas utilizadas, constituye un sistema de **código abierto** en su totalidad. Esto permite un sistema transparente y reproducible, sin dependencia de licencias comerciales.

3.4. Extracción de KPIs

Una de las fases más importantes del trabajo se constituye sobre cómo se evalúan los distintos resultados obtenidos por el simulador una vez se completa. Estas métricas surgen de la colaboración conjunta con la Empresa Municipal De Transportes, las cuales reflejan a tres escalas los distintos apartados de interés tanto a nivel empresa, con el fin de evaluar el grado de adecuación de una dotación de autobuses concreta a un escenario característico, como a nivel de validación propia del sistema, donde se comparan los resultados obtenidos con los resultados esperados derivados del análisis de la normalidad de los datos inicial.

3.4.1. Métricas a nivel general

Estos indicadores tratan de reflejar en un ámbito global, a modo de primera impresión, cuáles son los resultados de la simulación realizada. Se centran en condensar en porcentajes la media de los valores más relevantes que se pretende medir. Entre ellos destaca el **porcentaje medio de ocupación de los autobuses**, tanto global como fragmentado por sentido. Este porcentaje se realiza sobre una cota máxima definida por la EMT y fijada como estándar. el **tiempo medio de espera por pasajero**, agregado sobre el total de pasajeros a lo largo de las distintas iteraciones de *Monte Carlo*, o el valor medio de **regularidad**, también calculado sobre el total de iteraciones.

Esta regularidad representa un valor interno de la compañía municipal. Consiste en la medición y comparación de los tiempos realizados por los distintos autobuses en el tramo correspondido entre la segunda y la penúltima parada de la ruta. En la figura 3.2 se observa la fórmula utilizada para generar este valor.

El método de cálculo, del índice de regularidad para cada expedición, es el siguiente:

- Si el intervalo teórico It es menor o igual que 10 min., entonces el índice de regularidad IR
  - IR = **100** si Ir - It es menor o igual a 2 min., o
  - IR = $\mathbf{100} \times \left(\mathbf{1} - \left(\frac{I_r-(I_t+2)}{(I_t-2)}\right)\right)$ si Ir - It es mayor que 2 min.
- Si el intervalo teórico It es mayor que 10 min. y menor o igual a 25 min., entonces el índice de regularidad IR
  - IR = **100** si Ir es menor o igual 1,2It, o
  - IR = $\mathbf{100} \times \left(\mathbf{1} - \left(\frac{I_r-1{,}2I_t}{0{,}8I_t}\right)\right)$ si Ir - It es mayor que 1,2It.
- Si el intervalo teórico It es mayor que 25 min., entonces el índice de regularidad IR
  - IR = **100** si Ir - It es menor o igual a 5 min., o
  - IR = $\mathbf{100} \times \left(\mathbf{1} - \left(\frac{I_r-(I_t+5)}{(I_t-5)}\right)\right)$ si Ir - It es mayor que 5 min.
- Si un intervalo real es el doble del teórico entonces IR = 0

Los criterios para el cálculo de la regularidad son los siguientes:

- La regularidad se mide en la 2ª y penúltima parada de cada sentido de la expedición.
- El valor de regularidad de una franja es la media aritmética del valor IR obtenido para las paradas 2 y n-1 de la franja-parada-sentido.

Fuente: Documento interno otorgado por la EMT.

Fig. 3.2. Fórmula de regularidad para cada caso concreto de aplicación

3.4.2. Métricas a nivel de autobús

Se extraen parámetros a nivel de autobús correspondientes a cada viaje realizado por unidad física. La información contenida de cada expedición incluye **gráfico de evolución de ocupación a lo largo de la ruta**, **probabilidad del viaje de salir con retraso** y **tiempo medio en ese caso**, así como el valor de **regularidad** concreto del viaje.

3.4.3. Métricas a nivel de ruta

A nivel de ruta, se expone información concreta sobre cada parada, indicando **subidas**, **bajadas** y **tiempo medio de espera de los pasajeros**, pero reducido al filtro concreto de

esa parada. De forma paralela, se genera información sobre los tiempos entre paradas para los distintos tramos existentes en la ruta. Relativo al ámbito de validación del sistema, se muestran gráficas comparativas de valor de **ocupación** de los autobuses en esa parada, estudiando la *concordancia* con la distribución esperada, analizada y modelada de forma previa a la construcción del simulador. Esta similitud se estima mediante la extracción y comparación de medidas de distancia entre distribuciones, basada en los estudios y métricas de Bhattacharyya [65], que permiten, estableciendo un valor límite, o *threshold*, dirimir si dos distribuciones son similares.

Este trabajo establece la similitud mediante el coeficiente de Bhattacharyya para dos distribuciones normales bajo la premisa de que se cumple la hipótesis de normalidad sobre los datos simulados. En caso contrario, se aproximan las distribuciones mediante técnicas de Kernel Density Estimation (KDE) [66], aproximando posteriormente el coeficiente de Bhattacharyya a través de integración numérica trapezoidal.

4. ANÁLISIS DE LOS DATOS

En este capítulo se describe el proceso de análisis y procesado de los datos proporcionados por la EMT. Se ha dividido en tres etapas: **Limpieza y Preparación**, **Estudio y Gaussianidad** y **Preparación para Simulador**.

4.1. Limpieza y preparación

Esta sección detalla los distintos procedimientos seguidos en una primera fase iniciada tras la recepción de los datos provenientes de la EMT. Se distinguen dos tipos de datos principalmente: Datos Geoespaciales y Datos de Operación.

4.1.1. Datos geoespaciales

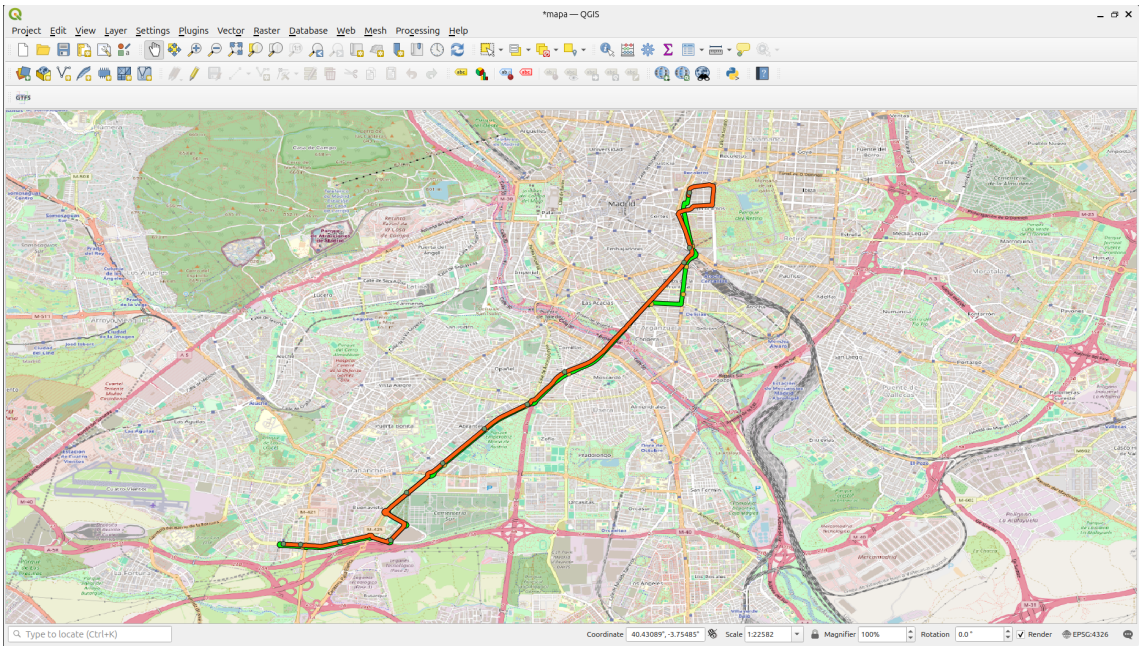
Estos datos se corresponden con elementos públicos obtenidos del **EMT Open Data Portal**[19], una iniciativa de la entidad que busca reforzar su compromiso con la transparencia y la colaboración para la mejora en la gestión [67]. Si bien el simulador no necesita la exacta localización de las paradas o de la ruta en cuestión, estos datos permiten una mejor visualización de cara a la construcción del modelo. Además, guardan información del orden y código numérico de las paradas, por lo que se impulsó su integración y tratamiento.

Dichos datos se encuentran en formato GeoJSON, un estándar dentro del ámbito geoespacial. No obstante, debido a la ubicación de estos dentro de un fichero de extensión «CSV», se encuentran mal formateados, presentando comillas simples «’ ’» en vez de comillas dobles «""», y juntando ambos sentidos de la ruta dentro de la misma celda.

Para subsanar esto, se recurre a un script de *Python* encargado de modificar las celdas correspondientes a los datos geo, separando en dos ficheros distintos según sentido y cambiando las ocurrencias de comillas simples por dobles. Por facilidad, además, se ramifican según si se corresponden con referencias a la trayectoria de la línea, o a instancias de paradas. De esta forma, se obtienen de cada ruta cuatro archivos, dos por cada sentido, donde uno contiene información de la topología de las uniones inter-parada, y el otro de los puntos referencia a las mismas.

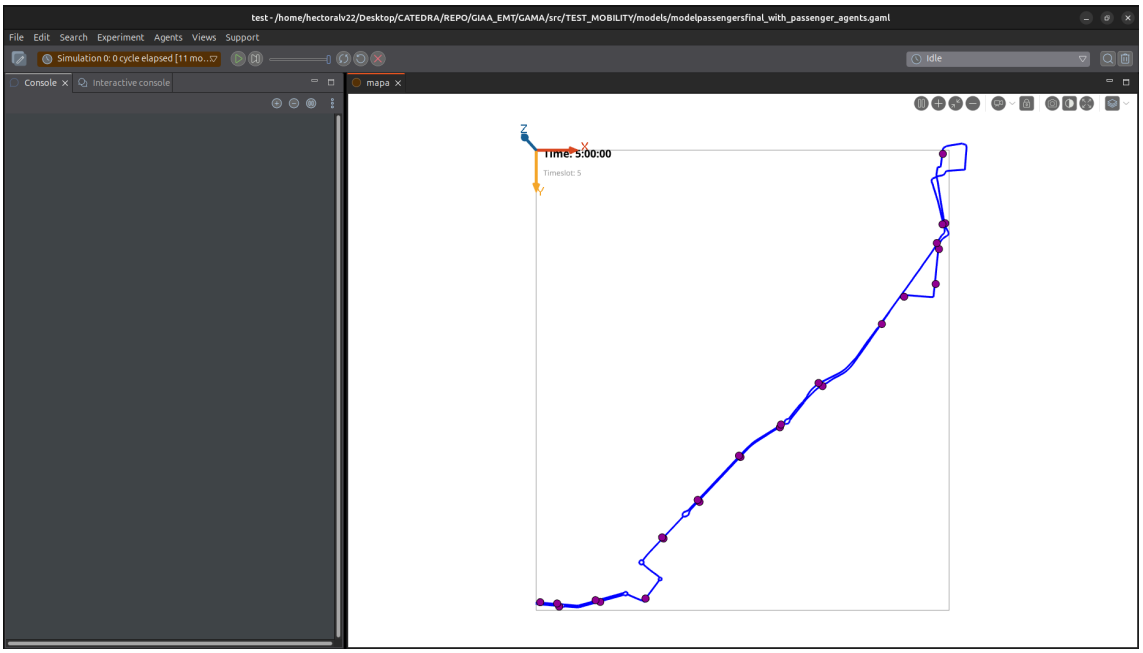
Como se especifica con anterioridad, aparte de la obtención y limpieza de los datos, para facilidad en la implementación, estos pasaron por un proceso de transformación a formato *ESRI shapefile*. Para ello se usa la herramienta de código abierto **QGIS**. En la figura 4.1 se muestra como se visualizan los cuatro GeoJSON procesados y transformados a shapefile. Posteriormente, en la figura 4.2 se muestran esos archivos shapefile ya dentro del entorno de trabajo de la plataforma de agentes GAMA.

[19] https://datos.emtmadrid.es/ (accedido: 9 de mayo de 2026)



Fuente: elaboración propia.

Fig. 4.1. Visualización en QGIS del mapa geoespacial convertido a shapefile



Fuente: elaboración propia.

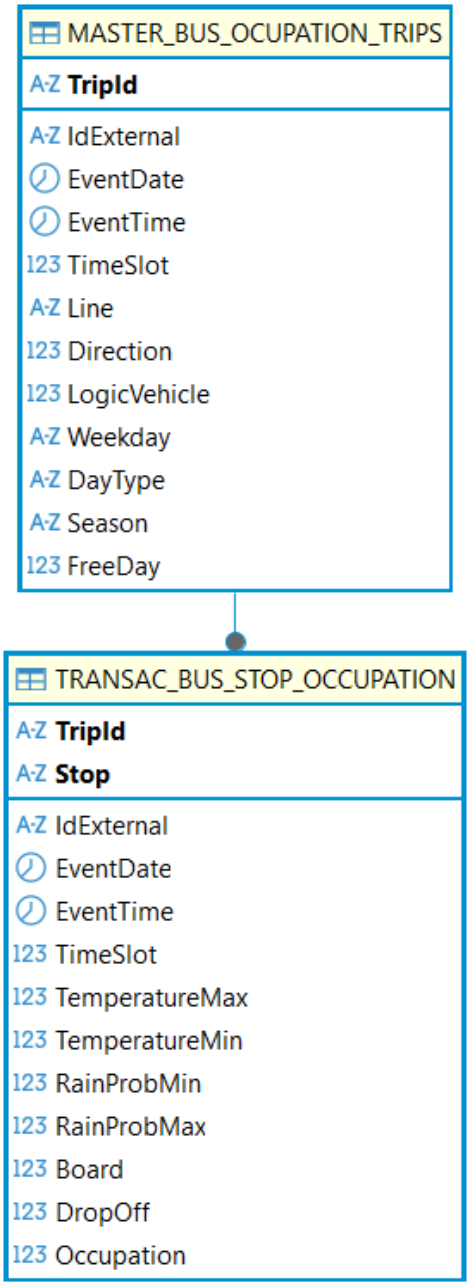
Fig. 4.2. Visualización en GAMA de los shapefile transformados

Estos datos no se usan en las siguientes fases, al no requerir mayor estudio sobre ellos. Se vuelven a abordar en el capítulo 5.

4.1.2. Datos de Operación

Los datos de operación representan la base empírica sobre la que se asienta el simulador. Su tratamiento supuso el inicio formal de la fase dos del proyecto «**Análisis y Parametrización**», comenzada una vez la EMT termina de preparar la base de datos en un servidor dedicado, incluyendo el pipeline que alimenta diariamente los datos. Los geoespaciales por su parte, al ser de acceso público, se pueden tratar sin la necesidad de preparación por parte de la empresa, por lo que se empiezan a tratar dentro de la fase previa a la mencionada.

Sobre la base de datos, en la figura 4.3 se puede ver el esquema relacional. Es un modelo sencillo compuesto por dos tablas, Master y Transaccional, relacionadas por *TripId*, identificador único de cada viaje. De esta forma, cada salida de cabecera representa una instancia de la tabla Master, mientras que cada llegada al resto de paradas de la ruta supone una entrada de la tabla transaccional, identificada por el mismo *TripId* y el código de parada.



Fuente: Documento facilitado por la EMT.

Fig. 4.3. Modelo Master:Transaccional de la base de datos

El resto de parámetros se especifican a continuación.

TABLA 4.1. PARÁMETROS DE LA TABLA MASTER

Nombre	Tipo de dato	Formato específico	Descripción
Master::IdExternal	UUID	NO	Identificador interno de la EMT. Se especificó no utilizarlo.
Master::EventDate	FECHA	YYYY-MM-DD	Referente al día del viaje.
Master::EventTime	FECHA	HH:MM:SS.f	Representativa del momento de inicio del viaje.
Master::TimeSlot	INT	NO	Franja horaria relativa a Master::EventTime.
Master::Line	STRING	NO	Código numérico identificador de la línea.
Master::Direction	INT	NO	Sentido del viaje. De forma interna el valor *1* representaba un sentido y *2* el opuesto.
Master::LogicVehicle	INT	NO	Identificador interno del coche encargado del viaje.
Master::Weekday	STRING	Inicial del día	Acrónimo referente al día de la semana específico.
Master::DayType	STRING	SI (Código Interno EMT)	Tipo de día. Existen múltiples valores posibles, principalmente se usa para diferenciar días laborables de fines de semana y festivos.
Master::Season	STRING	SI (Código Interno EMT)	Época del año relativa al día de recolección del dato.
Master::FreeDay	INT (BOOL)	1 ->true 0 ->false	Especifica si el día presenta *gratuidad*. El término se refiere a aquellos días específicos en los que el servicio del autobús se ofrece gratuito.

Fuente: Elaboración propia a partir de figura 4.3

TABLA 4.2. PARÁMETROS DE LA TABLA TRANSACCIONAL

Nombre	Tipo de dato	Formato específico	Descripción
Transac::IdExternal	UUID	NO	Mismo caso que en el parámetro de la tabla Master, se ignora.
Transac::EventDate	FECHA	YYYY-MM-DD	Mismo parámetro que en la tabla Master, salvo que debido a retrasos provoque la llegada al día siguiente en casos extremos al final de la jornada.
Transac::EventTime	FECHA	HH:MM:SS.f	Almacena el momento exacto en el que el bus llega a la parada específica.
Transac::TimeSlot	INT	NO	Franja horaria relativa al parámetro Transac::EventTime. Puede diferir del campo Master::TimeSlot.
Transac:: TemperatureMax	INT	NO	Previsión máxima de temperatura en la parada en el momento de la recolección del dato.
Transac:: TemperatureMin	INT	NO	Previsión mínima de temperatura en la parada en el momento de la recolección del dato.
Transac:: RainProbMax:	INT	NO	Valor máximo de probabilidad de precipitación registrado en el momento de llegada del autobús.
Transac:: RainProbMin:	INT	NO	Valor mínimo de probabilidad de precipitación registrado en el momento de llegada del autobús.
Transac::Board	INT	NO	Número de pasajeros que carga el autobús en el valor de la bitupla TripId-Stop.
Transac::DropOff	INT	NO	Número de pasajeros que abandonan el autobús.
Transac:: Occupation	INT	NO	Valor de la carga de pasajeros derivada del cálculo Transac::$Occupation$ = Transac::$Occupation_{\text{prev}}$ + Transac::$Board$−Transac::$DropOff$.

Fuente: Elaboración propia a partir de figura 4.3

El estudio ha derivado de distintas consultas sobre estas tablas, que encapsulaban en

un único fichero «CSV» toda la información referente a una parada. En el código 4.1 se muestra el código *SQL* utilizado para las consultas sobre la base de datos.

CÓDIGO 4.1. Datos totales de una parada

```
SELECT mbot.*, tbso.*
FROM UCIII.Transport.MASTER_BUS_OCUPATION_TRIPS mbot
JOIN UCIII.Transport.TRANSAC_BUS_STOP_OCCUPATION tbso
    ON tbso.TripId = mbot.TripId
    WHERE tbso.Stop = 'STOPCODE';
```

Fuente: Documento facilitado por la EMT.

El resultante «CSV» presentaba derivado del *JOIN* un problema, y era la duplicidad de nomenclatura en campos de ambas tablas, en concreto —*IdExternal*, *EventDate*, *EventTime* y *TimeSlot*—.

Como se ha mencionado, el análisis de los datos de operación se ha realizado con la herramienta **Jupyter Notebook**, usando kernel de *Python*. Bajo este framework, para el manejo de los volúmenes de datos se ha usado la librería *pandas*, que ante duplicidad en los nombres de los campos, al encontrar una segunda ocurrencia añade un «.1» al cuerpo de la columna. De esta forma, todos aquellos campos contenedores de un «.1» se corresponden con las referentes a la tabla Transaccional. De aquí en adelante, no obstante, para diferenciar ambos parámetros, aparecerá el prefijo *Transaccional::* o *Master::* para no generar ambigüedades.

En lo relativo a la limpieza de los datos, constituye una fase clave, dado que la no identificación de posibles anomalías en ciertos campos puede alterar la precisión del análisis posterior. En el caso particular, se redujo la limpieza a la eliminación de valores anómalos dentro de los campos *Transaccional::Occupation*, *Transaccional::Board* y *Transaccional::DropOff*, debido a la identificación de inconsistencias relativas a valores negativos en estos campos, o a valores extremos derivados de errores en la recolección. La EMT especificó que para los modelos de autobús utilizados de forma regular, un valor de *Ocupación* superior a 80 pasajeros nunca se iba a dar, por lo que se decidió, de cara a todo el trabajo, considerar ese valor como límite de la capacidad de carga. Como se comenta de forma exhaustiva en la siguiente sección, estos campos limpiados se presentan como los más importantes del análisis, motivo por el que se tratan con especial rigor para evitar problemas.

4.2. Estudio y Gaussianidad

En esta sección se documentan las dos etapas que componen el análisis de los datos. Este análisis se centra sobre dos pilares fundamentales, estudiar la viabilidad de los datos operacionales, y preparar los parámetros específicos para su inyección al simulador.

4.2.1. Estudio de viabilidad de datos operacionales

El principal reto de esta fase es la de evaluar la compatibilidad de los datos sobre los cuales se va a construir el simulador con los de una distribución normal. Como se especifica en la sección 3.1, una de las cuestiones de mayor relevancia de este proyecto es la simulación de los días **normales**. En el marco de este trabajo, se ha considerado día «normal» a aquel día laborable sin *gratuidad*. De esta forma, se excluyen fines de semana, festivos y días gratuitos. El motivo de esta segregación viene derivado del momento temporal en el que se comenzó esta etapa. Al no disponer de datos referentes al funcionamiento de las líneas previos a julio de 2025, la falta de datos festivos y de fines de semana relativos al número de datos laborables puede conducir a suposiciones sesgadas debido al reducido valor muestral de dichos datos.

El proceso de análisis se centra sobre un valor principal que es el de *Occupation*, perteneciente a la tabla **Transaccional** mencionada con anterioridad. Este valor es el más representativo como medida de estabilidad de los datos proporcionados por la EMT. Para evaluar su hipótesis de normalidad, se ha seguido un proceso iterativo. Dicho proceso inicia con la reducción del problema al mínimo posible, con el objetivo de ir validando resultados a medida que se expande la muestra estudiada.

La parada que se escoge para este estudio es la «5939:Vía Lusitana-Halconero del Rey». Se elige debido a su localización estratégica dentro de la ruta y a sus características propias. Es la quinta parada de la línea en sentido *Cibeles*, por lo que posible ruido o variabilidad inducida por las primeras paradas de la línea se mitiga. Con respecto a sus características, al no tener correspondencia con otras rutas, mitiga las variaciones derivadas de este hecho, como puede ser la absorción de demanda por otros autobuses.

El estudio en cuestión comienza aplicando un filtrado y estudiando la normalidad de los datos obtenidos. El filtro resulta de escoger de todos los *lunes laborables* el primer autobús que efectúa salida de cabecera en el *timeslot* correspondiente a las nueve de la mañana. Este filtro genera un número de observaciones a estudiar de unas 20 muestras. Este motivo, como se expone en el estado del arte, lleva a la decisión de aplicar un **test de normalidad** basado en «**skewness**» y «**kurtosis**». El test evalúa la hipótesis nula H_0: la distribución subyacente es normal, con un nivel de significación $\alpha = 0{,}05$. En aquellos casos en los que el test no rechaza H_0, se asume que los datos son compatibles con una distribución normal a un nivel de confianza del 95 % [56]. Este experimento documenta para cada llamada la hipótesis resultante, así como explicabilidad relativa a las causas de su aceptación o rechazo, basándose en estos valores de *skewness* y *kurtosis*. Como se discute en su respectiva sección del estado del arte, el test se junta con un estudio y selección de valores anómalos. Esta unión permite validar tanto las suposiciones de la normalidad del conjunto de datos a estudiar como, tanto si se cumple la hipótesis como en caso contrario, verificar y analizar aquellas instancias que según criterios estadísticos formales suponen un *outlier*.

El resultado de este filtro resulta en una aceptación de la hipótesis de normalidad para

la primera salida de cabecera de los buses en la franja de las nueve de la mañana. No obstante, al aplicar *ESD* [62] para la detección de anomalias, se detectan casos extremos que resulta necesario analizar. Ampliando este filtro temporal al resto de días laborables, los resultados son congruentes con lo observado en primera instancia: *Las observaciones realizadas sobre la primera salida de cabecera a las nueve de la mañana para todos los días laborables presentan una hipótesis válida de* ***normalidad***. Relativo a las anomalías detectadas, se observa de ellas un patrón claro, presentando todas valores de *Occupation* elevado con respecto a la muestra estudiada, y en todos los casos esos días se caracterizan por tener **gratuidad**. Esta observación lleva a la decisión de, en la fase de limpieza, ignorar aquellos casos que aun siendo días laborables, presentan este valor, ya que sus valores de *Occupation* tienden a inducir variación o ruido en el estudio.

Vale, en pseudorutinas, como integro esta parte. Idea, cometar un poco el análisis del primer filtro, comentar que se observan parámetros de normalidad, que una vez validado se expande a todos los de las nueve. Una vez validados esos se vuelve a expandir a martes, miercoles, jueves y viernes.

Despues de eso, ya se hace para todas las franjas para todas las paradas, y es cuando, mediante comparativas, se observa como debido a la baja poblacion muestral de algunos filtros, estos dan lugar a menos porcentaje de normalidad validada. Por esto, se decide evaluar el tratar a todos los días como iguales. El resultado es un mayor número de normalidad. Esto concluye el analisis de la viabilidad operacional, destacando que estos datos no se usan como inyeccion paramétrica al simulador, sino como contraste y evaluacion de los resultados de este. Expuesto en mayor profundidad en la fase de extraccion de resultados

4.3. Preparación para Simulador

En esta sección se exponen en profundidad los procesos relativos a la construcción de los parámetros que sirven de *input* a las simulaciones. Se presenta tanto la fase referente al estudio y análisis de las distribuciones de datos, como a la plantilla necesaria para que puedan ser ingestados en el simulador.

4.3.1. Estudio y análisis de carga, descarga y tiempo entre paradas

4.3.2. Adaptación de formato de parámetros de entrada

Aqui se especifica, que los parametros board, dropoff y timebetweenstops se tienen que guardar en ficheros csv, con una línea por parada, o tramos entre parada en el caso de tbs y que debe contener en el caso de boarddropoff en un fichero unico, un cambo disttype, param1, param2 y en el caso de tbs un campo mean y otro std.Especificar tambien que se tiene que crear un fichero json que permita parametrizar el número de autobuses físicos, y sus respectivas salidas de cabecera. Especifi-

car para cada archivo una plantilla

5. DISEÑO DE LA SIMULACIÓN

Aqui basicamente tengo que dividirlo en varias partes. Primeramente hablar del diseño y la eleccion como de la arquitectura de los agentes, el por qué de cada protocolo de comunicacion, como funciona un flujo de un autobus llegando a la parada, el tema del suavizado de cambios entre valores de franjas, etc. Tambien discutir sobre los dos modelos existentes, que el que incluye pasajeros puede ser considerado más "de agentes"por su comportamiento mas parecido a la realidad, con pasajeros que piden bajar, buses que rechazan subir más gente, y el otro que es más orientado a simulaciones rápidas(15 mins) pero que ambos generan mismos resultados sobre el papel. Puedo tmb meter una ontologia? Para mostrar un poco la arquitectura de los distintos elementos que componen cada simulacion. Hablar tambien de como se recogen los resultados, los logs etc

6. CASOS DE APLICACIÓN

7. MARCO REGULADOR

8. PRESUPUESTO Y COSTES

9. TRABAJOS FUTUROS

10. CONCLUSIÓN

BIBLIOGRAFÍA

[1] M.-P. Pelletier, M. Trépanier y C. Morency, "Smart card data use in public transit: A literature review," *Transportation Research Part C: Emerging Technologies*, vol. 19, n.º 4, pp. 557-568, 2011.

[2] S. Nesmachnow y D. Hernández, "Big Data Analysis for Travel Time Characterization in Public Transportation Systems," *Sustainability*, vol. 15, n.º 19, p. 14 561, 2023.

[3] P. Maes, "Modeling Adaptive Autonomous Agents," *Artificial Life*, vol. 1, n.º 1–2, pp. 135-162, 1993.

[4] N. R. Jennings y M. J. Wooldridge, "Applications of Intelligent Agents," en *Agent Technology: Foundations, Applications, and Markets*, N. R. Jennings y M. J. Wooldridge, eds., Berlin, Heidelberg: Springer-Verlag, 1998, pp. 3-28.

[5] H. S. Nwana, "Software Agents: An Overview," *The Knowledge Engineering Review*, vol. 11, n.º 3, pp. 205-244, 1996.

[6] M. Wooldridge y N. R. Jennings, "Intelligent Agents: Theory and Practice," *The Knowledge Engineering Review*, vol. 10, n.º 2, pp. 115-152, 1995.

[7] C. Castelfranchi, "Guarantees for Autonomy in Cognitive Agent Architecture," en *Intelligent Agents: Theories, Architectures, and Languages (LNAI Volume 890)*, M. Wooldridge y N. R. Jennings, eds., Springer-Verlag, 1995, pp. 56-70.

[8] R. A. Brooks, "A Robust Layered Control System for a Mobile Robot," *IEEE Journal on Robotics and Automation*, vol. 2, n.º 1, pp. 14-23, 1986.

[9] S. Franklin y A. Graesser, "Is It an Agent, or Just a Program? A Taxonomy for Autonomous Agents," en *Intelligent Agents III (LNAI Volume 1193)*, J. P. Müller, M. J. Wooldridge y N. R. Jennings, eds., Springer-Verlag, 1997, pp. 21-35.

[10] M. E. Bratman, *Intention, Plans, and Practical Reason*. Cambridge, MA: Harvard University Press, 1987.

[11] R. A. Brooks, "Elephants Don't Play Chess," en *Designing Autonomous Agents*, P. Maes, ed., Cambridge, MA: MIT Press, 1990, pp. 3-15.

[12] R. A. Brooks, "Intelligence Without Reason," en *Proceedings of the Twelfth International Joint Conference on Artificial Intelligence (IJCAI-91)*, Sydney, Australia, 1991, pp. 569-595.

[13] R. A. Brooks, "Intelligence Without Representation," *Artificial Intelligence*, vol. 47, pp. 139-159, 1991.

[14] I. A. Ferguson, "TouringMachines: An Architecture for Dynamic, Rational, Mobile Agents," Tesis doct., University of Cambridge, 1992.

[15] J. P. Müller, M. Pischel y M. Thiel, "Modeling Reactive Behaviour in Vertically Layered Agent Architectures," en *Intelligent Agents (LNAI Volume 890)*, M. Wooldridge y N. R. Jennings, eds., Springer-Verlag, 1995, pp. 261-276.

[16] E. Werner, "Logical Foundations of Distributed Artificial Intelligence," en *Foundations of Distributed Artificial Intelligence*, G. Weiss, ed., John Wiley & Sons, 1996, pp. 57-99.

[17] H. V. D. Parunak, "Applications of Distributed Artificial Intelligence in Industry," en *Foundations of Distributed Artificial Intelligence*, G. M. P. O'Hare y N. R. Jennings, eds., Wiley Inter-Science, 1996, pp. 139-164.

[18] M. Wooldridge, *An Introduction to MultiAgent Systems*, 2.ª ed. Chichester, UK: John Wiley & Sons, 2009.

[19] V. Botti, "Agentic AI and Multiagentic: Are We Reinventing the Wheel?" *arXiv preprint arXiv:2506.01463*, 2025.

[20] Foundation for Intelligent Physical Agents, *FIPA ACL Message Structure Specification*, FIPA Specification SC00061G, 2002. [En línea]. Disponible en: http://www.fipa.org/specs/fipa00061/.

[21] T. Finin, R. Fritzson, D. McKay y R. McEntire, "KQML as an Agent Communication Language," en *Proceedings of the Third International Conference on Information and Knowledge Management (CIKM-94)*, ACM, 1994, pp. 456-463.

[22] Foundation for Intelligent Physical Agents, *FIPA Communicative Act Library Specification*, FIPA Specification SC00037J, 2002. [En línea]. Disponible en: http://www.fipa.org/specs/fipa00037/.

[23] F. L. Bellifemine, G. Caire y D. Greenwood, *Developing Multi-Agent Systems with JADE*. Chichester, UK: John Wiley & Sons, 2007.

[24] U. Wilensky, *NetLogo*, Center for Connected Learning and Computer-Based Modeling, Northwestern University, 1999. [En línea]. Disponible en: http://ccl.northwestern.edu/netlogo/.

[25] S. Luke, C. Cioffi-Revilla, L. Panait, K. Sullivan y G. Balan, "MASON: A Multi-agent Simulation Environment," *Simulation*, vol. 81, n.º 7, pp. 517-527, 2005.

[26] R. H. Bordini, J. F. Hübner y M. Wooldridge, *Programming Multi-Agent Systems in AgentSpeak Using Jason*. John Wiley & Sons, 2007.

[27] P. Taillandier et al., "Building, composing and experimenting macroscopic models with the GAMA platform," *GeoInformatica*, vol. 23, n.º 2, pp. 299-322, 2019. [En línea]. Disponible en: https://gama-platform.org.

[28] M. Saidallah, A. El Fergougui y A. Elbelrhiti Elalaoui, "A Comparative Study of Urban Road Traffic Simulators," en *MATEC Web of Conferences*, vol. 81, EDP Sciences, 2016, p. 05 002. DOI: 10.1051/matecconf/20168105002.

[29] G. F. Newell y R. B. Potts, "Maintaining a Bus Schedule," en *Proceedings of the 2nd Australian Road Research Board (ARRB) Conference*, vol. 2, Melbourne, Australia: Australian Road Research Board, 1964, pp. 388-393.

[30] C. Wang, W. Chen, Y. Xu y Z. Ye, "Modeling Bus Capacity for Bus Stops Using Queuing Theory and Diffusion Approximation," *Transportation Research Record: Journal of the Transportation Research Board*, vol. 2675, n.º 12, pp. 651-663, 2021. DOI: 10.1177/03611981211030257.

[31] C. Wang, Z. Ye, J. D. Fricker, Y. Zhang y S. V. Ukkusuri, "Bus Capacity Estimation Using Stochastic Queuing Models for Isolated Bus Stops in China," *Transportation Research Record: Journal of the Transportation Research Board*, vol. 2672, n.º 8, pp. 108-120, 2018. DOI: 10.1177/0361198118777358.

[32] T. Liu, W. Ji, K. Gkiotsalitis y O. Cats, "Optimizing Public Transport Transfers by Integrating Timetable Coordination and Vehicle Scheduling," *Computers & Industrial Engineering*, vol. 184, p. 109 577, 2023. DOI: 10.1016/j.cie.2023.109577.

[33] M. Li, Y. Yin, W.-B. Zhang, K. Zhou y H. Nakamura, "Performance of the Priority Control Strategies for Bus Rapid Transit: Comparative Study from Scenario Microsimulation Using VISSIM," *Discrete Dynamics in Nature and Society*, vol. 2013, p. 398 938, 2013. DOI: 10.1155/2013/398938.

[34] K. E. Zannat, J. Laudan, C. F. Choudhury y S. Hess, "Developing an Agent-Based Microsimulation for Predicting the Bus Rapid Transit (BRT) Demand in Developing Countries: A Case Study of Dhaka, Bangladesh," *Transport Policy*, vol. 148, pp. 92-106, 2024. DOI: 10.1016/j.tranpol.2023.12.014.

[35] A. Tirachini, S. Medina y J. Moya, "A Discrete-Event Public Transportation Simulation Model to Evaluate Travel Demand Management Impacts on Waiting Times and Crowding Conditions," *Case Studies on Transport Policy*, vol. 14, p. 101 077, 2023. DOI: 10.1016/j.cstp.2023.101077.

[36] E. H. Arias Nava, L. A. Moncayo-Martínez et al., "A Data-Driven Discrete-Event Simulation for Assessing Passenger Dynamics and Bottlenecks in Mexico City Metro Line 7," *Modelling*, vol. 7, n.º 2, p. 58, 2026. DOI: 10.3390/modelling7020058.

[37] M. Owais y M. K. Osman, "Complete Hierarchical Multi-Objective Genetic Algorithm for Transit Network Design Problem," *Expert Systems with Applications*, vol. 114, pp. 143-154, 2018. DOI: 10.1016/j.eswa.2018.07.065.

[38] S. B. Jha, J. Jha y M. K. Tiwari, "A Multi-Objective Meta-Heuristic Approach for Transit Network Design and Frequency Setting Problem in a Bus Transit System," *Computers & Industrial Engineering*, vol. 130, pp. 166-186, 2019. DOI: 10.1016/j.cie.2019.02.025.

[39] A. Saval et al., "Dealing with Mixed and Non-Normative Traffic. An Agent-Based Simulation with the GAMA Platform," *PLoS ONE*, vol. 18, n.º 3, e0281658, 2023. DOI: 10.1371/journal.pone.0281658.

[40] R. A. Shaharuddin y M. Y. Misro, "Traffic Simulation Using Agent Based Modelling," en *AIP Conference Proceedings*, vol. 2423, AIP Publishing, 2021, p. 020 035. DOI: 10.1063/5.0075719.

[41] J. Bajada, J. Grech y T. Bajada, "Deep Reinforcement Learning of Autonomous Control Actions to Improve Bus-Service Regularity," en *Artificial Intelligence. ECAI 2023 International Workshops*, S. Nowaczyk et al., eds., ép. Communications in Computer and Information Science, vol. 1947, Cham: Springer, 2024. DOI: 10.1007/978-3-031-50396-2_8.

[42] Y. Tang et al., "Robust Reinforcement Learning Strategies with Evolving Curriculum for Efficient Bus Operations in Smart Cities," *Smart Cities*, vol. 7, n.º 6, pp. 3658-3677, 2024. DOI: 10.3390/smartcities7060141.

[43] P. Alvarez Lopez et al., "Microscopic Traffic Simulation using SUMO," en *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, IEEE, 2018, pp. 2575-2582. DOI: 10.1109/ITSC.2018.8569938.

[44] M. Fellendorf y P. Vortisch, "Microscopic Traffic Flow Simulator VISSIM," en *Fundamentals of Traffic Simulation*, ép. International Series in Operations Research & Management Science, J. Barceló, ed., vol. 145, New York, NY: Springer, 2010, pp. 63-93. DOI: 10.1007/978-1-4419-6142-6_2.

[45] A. Divasson-J., A. M. Macarulla, J. I. Garcia y C. E. Borges, "Agent-based Modeling in Urban Human Mobility: A Systematic Review," *Cities*, vol. 158, p. 105 697, 2025. DOI: 10.1016/j.cities.2024.105697.

[46] N. Morri, S. Hadouaj y L. Ben Said, "An Approach to Intelligent Control Public Transportation System Using a Multi-agent System," en *Enterprise Information Systems: ICEIS 2020*, ép. Lecture Notes in Business Information Processing, J. Filipe, M. Śmiałek, A. Brodsky y S. Hammoudi, eds., vol. 417, Cham: Springer, 2021, pp. 249-272. DOI: 10.1007/978-3-030-75418-1_12.

[47] F. Chambers, G. Di Marzo Serugendo y C. Cruz, "Autonomous Generation of a Public Transportation Network by an Agent-Based Model: Mutual Enrichment with Knowledge Graphs for Sustainable Urban Mobility," *Sustainability*, vol. 16, n.º 20, p. 8907, 2024. DOI: 10.3390/su16208907.

[48] M. Fanfani, A. Giovannoni, L. A. Ipsaro Palesi, A. Irum y P. Nesi, "Fast Agent-Based Solution to Evaluate the Matching of Public Transport Offer vs Citizen Mobility Demand," en *Computational Science and Its Applications – ICCSA 2025 Workshops*, O. Gervasi et al., eds., ép. Lecture Notes in Computer Science, vol. 15898, Cham: Springer, 2025, pp. 255-272. DOI: 10.1007/978-3-031-97657-5_16.

[49] N. Metropolis y S. Ulam, "The Monte Carlo Method," *Journal of the American Statistical Association*, vol. 44, n.º 247, pp. 335-341, 1949. DOI: 10.1080/01621459.1949.10483310.

[50] A. N. Kolmogorov, *Grundbegriffe der Wahrscheinlichkeitsrechnung* (Ergebnisse der Mathematik und ihrer Grenzgebiete 3). Berlin: Julius Springer, 1933, vol. 2. DOI: 10.1007/978-3-642-49888-6.

[51] Federal Highway Administration, "Traffic Analysis Toolbox Volume III: Guidelines for Applying Traffic Microsimulation Modeling Software — 2019 Update," U.S. Department of Transportation, inf. téc. FHWA-HOP-18-036, 2019. [En línea]. Disponible en: https://ops.fhwa.dot.gov/publications/fhwahop18036/.

[52] A. de Moivre, *The Doctrine of Chances: or, A Method of Calculating the Probabilities of Events in Play*, 2.ª ed. London: H. Woodfall, 1738.

[53] P.-S. Laplace, *Théorie analytique des probabilités*. Paris: Courcier, 1812.

[54] C. F. Gauss, *Theoria motus corporum coelestium in sectionibus conicis solem ambientium*. Hamburg: F. Perthes et I.H. Besser, 1809.

[55] B. W. Yap y C. H. Sim, "Comparisons of Various Types of Normality Tests," *Journal of Statistical Computation and Simulation*, vol. 81, n.º 12, pp. 2141-2155, 2011.

[56] H.-Y. Kim, "Statistical Notes for Clinical Researchers: Assessing Normal Distribution Using Skewness and Kurtosis," *Restorative Dentistry & Endodontics*, vol. 38, n.º 1, pp. 52-54, 2013.

[57] R. B. D'Agostino y E. S. Pearson, "Tests for Departure from Normality. Empirical Results for the Distributions of b_2 and $\sqrt{b_1}$," *Biometrika*, vol. 60, n.º 3, pp. 613-622, 1973.

[58] A. C. Cameron y P. K. Trivedi, *Regression Analysis of Count Data*, 2.ª ed. Cambridge University Press, 2013.

[59] K. Pearson, "On the Criterion that a Given System of Deviations from the Probable in the Case of a Correlated System of Variables is Such that it Can Be Reasonably Supposed to Have Arisen from Random Sampling," *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, vol. 50, n.º 302, pp. 157-175, 1900.

[60] W. G. Cochran, "Some Methods for Strengthening the Common Chi-Squared Tests," *Biometrics*, vol. 10, n.º 4, pp. 417-451, 1954.

[61] National Institute of Standards and Technology, *Detection of Outliers*, NIST/SEMATECH e-Handbook of Statistical Methods, 2012. [En línea]. Disponible en: https://www.itl.nist.gov/div898/handbook/eda/section3/eda35h.htm#Normality.

[62] B. Rosner, "Percentage Points for a Generalized ESD Many-Outlier Procedure," *Technometrics*, vol. 25, n.º 2, pp. 165-172, 1983.

[63] R. R. Wilcox, *Introduction to Robust Estimation and Hypothesis Testing*, 3.ª ed. Academic Press, 2012.

[64] C. Leys, C. Ley, O. Klein, P. Bernard y L. Licata, "Detecting Outliers: Do Not Use Standard Deviation Around the Mean, Use Absolute Deviation Around the Median," *Journal of Experimental Social Psychology*, vol. 49, n.º 4, pp. 764-766, 2013.

[65] A. Bhattacharyya, "On a Measure of Divergence between Two Multinomial Populations," *Sankhyā: The Indian Journal of Statistics (1933–1960)*, vol. 7, n.º 4, pp. 401-406, 1946. [En línea]. Disponible en: https://www.jstor.org/stable/25047882.

[66] B. W. Silverman, *Density Estimation for Statistics and Data Analysis* (Monographs on Statistics and Applied Probability). London: Chapman y Hall, 1986.

[67] S. Balaguer, M. Fernández y A. Martín, "Data as an asset: EMT open platform for transport data in Madrid," *Collection of Open Conferences in Research Transport*, vol. 2018, 2018. DOI: 10.5281/zenodo.1441026.

ANEXO A. ESPECIFICACIÓN DE REQUISITOS DEL SISTEMA

A.1 Introducción

[Texto introductorio aquí]

A.2 Requisitos Funcionales

RF-01 — [NOMBRE CORTO DEL REQUISITO]

Identificador	RF-01
Nombre	[Nombre corto del requisito]
Tipo	Funcional
Prioridad	Must
Fuente	[Fuente: tutor, normativa EMT, IEEE 29148, etc.]
Descripción	[Descripción completa, precisa y verificable del comportamiento requerido.]
Justificación	[Por qué este requisito es necesario.]
Dependencias	RF-XX, RNF-XX o Ninguna
Verificación	[Como se comprueba que el requisito se cumple Metodo T/I/A/D]